

데이터 과학

2026학년도 1학기 데이터 과학 교수학습 및 세부 평가 계획

학교명	학년	과목	학기	학급	지도교사
오현고등학교	2학년	데이터 과학	1학기	3, 4, 9반	000

1 데이터 과학 교수학습 및 평가 방법

2026학년도 1학기 교과진도 운영 계획서						담당 교사: 000		
시기		시수/ 누계	단원명	교육과정 (성취기준)	수업-평가 방법, 수업-평가 연계의 주안점			비고 (학교 행사)
					수업방법	평가방법	안전/진로/다문화 교육 운영 계획	
3월	1주	2/2	1. 데이터 과학의 이해 (1)데이터 과학과 데이터 1)데이터 과학의 개념	[12데과01-01]	■강의식수업	■ 퀴즈		·대체공휴일(2) ·1학기 개학(3)
	2주	3/5	1. 데이터 과학의 이해 (1)데이터 과학과 데이터 2) 데이터의 형태와 속성	[12데과01-02]	■강의식수업	■ 퀴즈		
	3주	3/8	1. 데이터 과학의 이해 (2)데이터의 저장과 활용 1) 데이터와 데이터베이스 2) 데이터와 미래 사회	[12데과01-03] [12데과01-04]	■강의식수업	■ 퀴즈		
	4주	3/11	2. 데이터 준비와 분석 (1)데이터 준비 1)데이터 수집과 선택 2) 데이터 전처리와 시각화	[12데과02-01]	■강의식수업 ■실습활동수업	■ 퀴즈		
	5주	3/14	2. 데이터 준비와 분석 (2)데이터 분석 1)데이터 분석 방법	[12데과02-02]	■강의식수업 ■실습활동수업	■ 퀴즈		

2026학년도 1학기 교과진도 운영 계획서

담당 교사: 000

시기	시수/ 누계	단원명	교육과정 (성취기준)	수업-평가 방법, 수업-평가 연계의 주안점			비고 (학교 행사)
				수업방법	평가방법	안전/진로/다문화 교육 운영 계획	
4월	1주	0/14	2. 데이터 준비와 분석 (2)데이터 분석 1)데이터 분석 방법	[12데과02-02]			
	2주	3/17	2. 데이터 준비와 분석 (2)데이터 분석 2)데이터 분석의 실제	[12데과02-02] [12데과02-03] [12데과02-04]	■ 강의식수업 ■ 실습활동수업	■ 퀴즈	
	3주	3/20	3. 데이터 모델링과 평가 (1)데이터 모델과 회귀분석 1)데이터 모델	[12데과03-01] [12데과03-02]	■ 강의식수업 ■ 실습활동수업	■ 퀴즈	
	4주	3/23	2) 회귀분석 3. 데이터 모델링과 평가 (1)데이터 모델과 회귀분석 1)데이터 모델	[12데과03-01] [12데과03-02]	■ 강의식수업 ■ 실습활동수업	■ 퀴즈	
	5주	0/23	2) 회귀분석	[12데과03-01] [12데과03-02]			·1차 정기시험 (27~29) ·학교운동회 (30)

2026학년도 1학기 교과진도 운영 계획서

담당 교사: 000

시기	시수/ 누계	단원명	교육과정 (성취기준)	수업-평가 방법, 수업-평가 연계의 주안점			비고 (학교 행사)
				수업방법	평가방법	안전/진로/다문화 교육 운영 계획	
5월	1주	0/23	[12데과03-01] [12데과03-02]				·학교운동회 (1)
	2주	3/26	3. 데이터 모델링과 평가 (2)군집 분석과 연관 분석 1) 군집분석 3. 데이터 모델링과 평가 (2)군집 분석과 연관 분석	[12데과03-01] [12데과03-03]	■ 강의식수업 ■ 실습활동수업		·재량휴업일(4) ·어린이날(5)
	3주	2/28	3. 데이터 모델링과 평가 (2)군집 분석과 연관 분석 2) 연관분석 3. 데이터 모델링과 평가 (2)군집 분석과 연관 분석	[12데과03-04]	■ 강의식수업 ■ 실습활동수업		·1,2학년 현장체험학습(13~15)
	4주	3/31	2) 연관분석 3. 데이터 모델링과 평가 (2)군집 분석과 연관 분석	[12데과03-04] [12데과03-05] [12데과03-06]	■ 강의식수업 ■ 실습활동수업	■ 퀴즈	
	5주	3/34	4. 데이터 과학 프로젝트 (1)데이터 과학과 문제해결 1)데이터 과학으로 문제해결	[12데과04-01]	■ 강의식수업 ■ 실습활동수업	■ 퀴즈	·대체공휴일(25)

2026학년도 1학기 교과진도 운영 계획서

담당 교사: 000

시기	시수/ 누계	단원명	교육과정 (성취기준)	수업-평가 방법, 수업-평가 연계의 주안점			비고 (학교 행사)
				수업방법	평가방법	안전/진로/다문화 교육 운영 계획	
6월	1주	3/37	4. 데이터 과학 프로젝트 (1)데이터 과학과 문제해결 1)데이터 과학으로 문제해결	[12데과04-01] [12데과04-02]	■강의식수업 ■실습활동수업	■ 퀴즈	·지방선거일(3)
	2주	3/40	4. 데이터 과학 프로젝트 (1)데이터 과학과 문제해결 1) 일상 생활의 데이터에 기반한 스트레스 지수 예측	[12데과04-01] [12데과04-02] [12데과04-03] [12데과04-04]	■강의식수업 ■실습활동수업	■ 퀴즈	
	3주	3/43	4. 데이터 과학 프로젝트 (2)데이터 과학 프로젝트 실제 1)영화 데이터 분석과 관객 수 예측	[12데과04-01] [12데과04-02] [12데과04-03] [12데과04-04]	■강의식수업 ■실습활동수업	■ 퀴즈	
	4주	3/46	4. 데이터 과학 프로젝트 (2)데이터 과학 프로젝트 실제 2)긴급 지원이 필요한 국가 군집 분석	[12데과04-01] [12데과04-02] [12데과04-03] [12데과04-04]	■강의식수업 ■실습활동수업	■ 퀴즈	
	5주	3/49	4. 데이터 과학 프로젝트 (2)데이터 과학 프로젝트 실제 - 프로젝트 실습 활동	[12데과04-01] [12데과04-02] [12데과04-03] [12데과04-04]	■강의식수업 ■실습활동수업	■ 퀴즈	

2026학년도 1학기 교과진도 운영 계획서

담당 교사: 000

시기	시수/ 누계	단원명	교육과정 (성취기준)	수업-평가 방법, 수업-평가 연계의 주안점			비고 (학교 행사)
				수업방법	평가방법	안전/진로/다문화 교육 운영 계획	
7월	1주	0/49	4. 데이터 과학 프로젝트 (2)데이터 과학 프로젝트 실제 - 프 로젝 트 실습 활동	[12데과04-01] [12데과04-02] [12데과04-03] [12데과04-04]	■강의식수업 ■실습활동수업	■ 퀴즈	·2차 정기시험 (3)
	2주	0/49					·2차 정기시험 (6~7) ·자율적 교육과정 (9~10)
	3주	2/51	진로탐색	[12데과04-01] [12데과04-02] [12데과04-03] [12데과04-04]	■ 토의수업 (모둠활동)	■ 관찰 동료 평가	·자율적 교육과정 (13~16) ·제한질(17)
	4주	0/48					·여름방학(21~8/17)

2 데이터 과학 세부평가계획

1 평가의 목적

‘데이터 과학’은 컴퓨팅 사고력을 기반으로 디지털 사회에서 데이터의 역할 및 잠재적 가치와 데이터 과학에 기반한 문제 해결 과정의 중요성을 인식하며, 다양한 분야의 문제를 해결하고 합리적 의사 결정을 위한 통찰의 역량을 키우는 데 중점을 둔다.

- 가. 데이터 과학의 발전에 따른 사회의 특성과 데이터의 가치를 이해하고, 데이터에 기반한 합리적인 의사 결정을 실천하는 태도를 기른다.
- 나. 데이터 분석과 관련된 효과적인 방법을 이해하고, 문제상황에 따라 데이터의 관계를 파악하여 다양한 분석 방법을 적용할 수 있는 능력을 기른다.
- 다. 문제를 합리적으로 해결하기 위한 모델을 구성하고, 문제 해결 과정에서 발생할 수 있는 여러 쟁점을 비교하며, 분석된 결과의 의미를 찾아 비판적으로 해석하는 능력과 태도를 기른다.
- 라. 데이터 과학을 기반으로 한 문제 해결이 합리적 의사 결정에 효과적임을 인식하고, 데이터 과학의 방법으로 문제를 해결하는 능력과 태도를 기른다.

2 평가의 기본 방향과 방침, 유의사항, 결과의 활용

가. 기본방향

- 1) 평가 항목은 컴퓨팅 사고력, 디지털 문화 소양, 인공지능 소양의 하위 요소를 기반으로 구체화한다.
- 2) 평가 내용은 지식·이해뿐 아니라, 과정·기능, 가치·태도의 측면 등을 다면적으로 반영하고 과정을 중시하는 평가를 통해 학생의 성장과 발달을 돕는 평가를 실현한다.
- 3) 구체적인 평가 루브릭을 학생과 함께 구성하는 과정을 통해 학생이 자신의 학습 수준을 파악하고 스스로 학습을 성찰할 수 있는 기회를 제공하여, 적극적이고 능동적인 학습이 이루어지도록 한다.
- 4) 작성한 프로그램의 정확성, 효율성과 더불어 프로그램 설계 과정의 논리성과 실습 과정을 통해 데이터 모델링의 과정을 이해하고 있는지에 중점을 두고 평가한다.

나. 방침

- 1) 정기시험은 선택형으로 평가한다.
- 2) 정기시험은 사고력, 문제 해결력, 창의력 등 고등사고기능을 평가하도록 한다.
- 3) 평가 문항의 출제는 문항의 타당도, 신뢰도, 난이도, 객관도 등을 고려하여야 한다.
- 4) 서술형 배점은 정수 배점으로 한다.

다. 유의사항

- 1) 모든 평가는 동일한 기준을 제시하여 적용하고, 결과를 공개하여 공정성을 기하도록 한다.
- 2) 평가 계획서에 명시되지 않은 사안이 발생하는 경우 학업성적관리위원회에서 결정한다.

라. 결과의 활용

- 1) 평가 결과는 학습자의 성취 수준, 교과 능력의 발달 정도를 판단하고, 교수·학습 방법, 교수·학습 자료, 평가 도구를 개선하는 데 활용한다.
- 2) 평가 결과를 통해 학습자의 성취 수준 이외에 교수·학습에 영향을 미치는 여러 요인을 분석하여 학습자의 교과 능력을 향상과 인성, 진로 교육, 학부모 상담 자료로 활용한다.

3 세부 평가 계획

평가 종류	정기시험(60%)				수행평가(40%)		총점
영역	1차 정기시험		2차 정기시험		데이터 과학 적용 사례 모델 분석하기	데이터 분석 프로젝트	400
	I. 데이터 과학의 이해 II. 데이터 준비와 분석 III. 데이터 모델링과 평가		I. 데이터 과학의 이해 II. 데이터 준비와 분석 III. 데이터 모델링과 평가 IV. 데이터 과학 프로젝트		I. 데이터 과학의 이해 II. 데이터 준비와 분석 III. 데이터 모델링과 평가	II. 데이터 준비와 분석 III. 데이터 모델링과 평가 IV. 데이터 과학 프로젝트	
방법	선택형	서답형	선택형	서답형	서술형	서술형	
배점 (반영비율)	100	0	100	0	100	100	
	30%	0%	30%	0%	20%	20%	100%
서(논)술형 평가 반영비율 (100%기준)	0%				20%	20%	40%
시기	4월		7월		5월	6월	
평가내용 (성취기준)	[12데과01-01] [12데과01-02] [12데과01-03] [12데과01-04] [12데과02-01] [12데과02-02] [12데과02-03] [12데과02-04] [12데과03-01] [12데과03-02] [12데과03-03] [12데과03-04] [12데과03-05] [12데과03-06] [12데과04-01] [12데과04-02] [12데과04-03] [12데과04-04] [12데과04-05]		[12데과01-01] [12데과01-02] [12데과01-03] [12데과01-04] [12데과02-01] [12데과02-02] [12데과02-03] [12데과02-04] [12데과03-01] [12데과03-02] [12데과03-03] [12데과03-04] [12데과03-05] [12데과03-06] [12데과04-01] [12데과04-02] [12데과04-03] [12데과04-04] [12데과04-05]		[12데과02-01] [12데과02-02] [12데과02-03] [12데과02-04] [12데과03-01] [12데과03-02] [12데과03-03] [12데과03-04] [12데과03-05] [12데과03-06] [12데과04-01] [12데과04-02] [12데과04-03] [12데과04-04] [12데과04-05]	[12데과02-01] [12데과02-02] [12데과02-03] [12데과02-04] [12데과03-01] [12데과03-02] [12데과03-03] [12데과03-04] [12데과03-05] [12데과03-06] [12데과04-01] [12데과04-02] [12데과04-03] [12데과04-04] [12데과04-05]	

4 성취평가제 기준성취율, 성취도

석차등급 산출	5등급			
성취도	5단계(A-B-C-D-E)			
학기말 성취율과 성취도	성취율		성취도	
	90%이상		A	
	80%이상 ~ 90% 미만		B	
	70%이상 ~ 80% 미만		C	
	60%이상 ~ 70% 미만		D	
	40% 이상 ~ 60% 미만		E	
정기시험 고사별 분할점수	성취수준별 추정분할점수			
수행평가 영역별 분할점수	데이터 과학 적용 사례 모델 분석하기 (100점 만점)		데이터 분석 프로젝트 (100점 만점)	
	성취도 구분	분할점수	성취도 구분	분할점수
	A/B	90	A/B	90
	B/C	70	B/C	70
	C/D	50	C/D	50
	D/E	30	D/E	30

5 수행평가 영역별 세부기준(배점 및 채점기준)

○ 데이터 과학 적용 사례 모델 분석하기 채점 기준표(100점)

수행 과제	데이터 과학이 적용된 사례에 대해 자료를 수집 및 분석, 모델에 대해 분석 보고서 작성하기		
교육과정 성취기준	[12데과02-01],[12데과02-02],[12데과02-03],[12데과02-04],[12데과03-01],[12데과03-02],[12데과03-03],[12데과03-04],[12데과03-05],[12데과03-06]		
평가기준	상	데이터 과학 적용 사례와 해당 사례에서 활용된 데이터의 특성과 분석 모델에 대한 이해를 바탕으로 데이터 활용 과정을 논리적으로 설명할 수 있으며, 데이터 모델의 특징과 활용 결과를 분석하고 평가할 수 있다.	
	중	데이터 과학 적용 사례와 해당 사례에서 활용된 데이터와 분석 모델에 대한 기본적인 이해를 바탕으로 데이터 활용 사례를 설명할 수 있으며, 데이터 모델의 특징을 부분적으로 분석할 수 있다.	
	하	데이터 과학 적용 사례에 대한 기초적인 이해를 바탕으로 데이터 활용 사례를 설명할 수 있으나, 데이터 모델의 특징이나 활용 과정을 분석하는 데에는 어려움이 있다.	
평가방법	☒ 서술·논술 ☐ 구술·발표 ☐ 토의·토론 ☐ 프로젝트 ☐ 실험·실습 ☒ 포트폴리오 ☐ 기타		
	☒ 교사 관찰 및 기록 ☐ 자기평가 ☐ 동료평가		
평가 요소	수행수준(채점기준)		배점
데이터 과학 적용 사례 조사 및 이해하기 (25점)	데이터 과학이 활용된 실제 사례를 선정하고 문제 상황, 활용 목적, 적용 분야를 모두 포함하여 구체적으로 설명함.		25
	데이터 과학 사례를 제시하고 문제 상황과 활용 목적을 설명함.		20
	데이터 과학 사례를 제시하였으나 문제 상황 또는 활용 목적 설명이 부족함.		15
	사례는 제시하였으나 데이터 과학 활용 내용이 불명확함.		10
	적절한 데이터 과학 사례를 제시하지 못함.		5
데이터 기반 문제 해결 과정 설명하기 (25점)	문제 정의, 데이터 수집, 데이터 분석, 결과 활용의 데이터 과학 과정 4단계를 모두 설명함.		25
	데이터 과학 과정 중 3단계를 설명함.		20
	데이터 과학 과정 중 2단계를 설명함.		15
	데이터 과학 과정 중 1단계만 설명함.		10
	데이터 활용 과정 설명이 이루어지지 않음.		5
데이터 모델, 분석 방법 이해하기 (25점)	사례에 사용된 데이터 분석 방법 또는 모델의 원리와 특징을 모두 설명하고 적용 목적을 설명함.		25
	데이터 분석 방법 또는 모델의 특징과 활용 목적을 설명함.		20
	데이터 모델 또는 분석 방법을 단순히 설명함.		15
	모델 설명이 부정확하거나 이해가 부족함.		10
	데이터 모델 또는 분석 방법을 설명하지 못함.		5
데이터 활용 결과 및 한계 분석하기 (25점)	데이터 활용 결과를 논리적으로 설명하고 한계점 또는 개선 방향을 적절하게 제시함.		25
	데이터 활용 결과와 한계점 중 하나를 제시함.		20
	데이터 활용 결과만 설명함.		15
	데이터 활용 결과 설명이 부족하거나 한계 분석이 미흡함.		10
	데이터 활용 결과와 한계를 적절히 분석하지 못함.		5

○ 데이터 분석 프로젝트 채점기준표(100점)

수행 과제	실생활 또는 사회 현상과 관련된 주제를 선정 및 관련된 데이터를 다양한 방법을 통해 수집하여 데이터 과학으로 접근하고 분석할 수 있다.	
교육과정 성취기준	[12데과02-01] [12데과02-02][12데과02-03] [12데과02-04][12데과03-01] [12데과03-02][12데과03-03] [12데과03-04][12데과03-05] [12데과03-06][12데과04-01] [12데과04-02][12데과04-03] [12데과04-04][12데과04-05]	
평가기준	상	데이터 분석 주제를 설정하고 목적에 맞는 데이터를 수집한 후 데이터를 체계적으로 정리·분석하여 의미 있는 결과를 도출할 수 있으며, 분석 결과를 적절한 시각화 자료로 표현하고 논리적으로 해석하여 데이터 기반 의사결정을 설명할 수 있다.
	중	데이터 분석 주제를 설정하고 데이터를 수집하여 기본적인 데이터 정리 및 분석을 수행할 수 있으며, 분석 결과를 그래프나 표 등으로 표현하고 데이터 분석 결과를 설명할 수 있다.
	하	데이터 분석 주제를 설정하고 데이터를 수집하여 간단한 데이터 정리나 분석을 수행할 수 있으며, 분석 결과를 바탕으로 자신의 생각을 부분적으로 설명할 수 있다.
평가방법	☒ 서술·논술 ☐ 구술·발표 ☐ 토의·토론 ☒ 프로젝트 ☐ 실험·실습 ☒ 포트폴리오 ☐ 기타	
	☒ 교사 관찰 및 기록 ☐ 자기평가 ☐ 동료평가	
평가 요소	수행수준(채점기준)	배점
데이터 분석 주제 설정 및 데이터 수집하기 (25점)	분석 목적이 명확한 주제를 설정하고 분석에 필요한 데이터를 2종 이상 직접 수집하거나 공공데이터 등을 활용하여 적절히 제시함.	25
	분석 주제를 설정하고 데이터를 수집하였으나 데이터 종류가 1종이거나 수집 과정 설명이 일부 부족함.	20
	분석 주제는 있으나 데이터의 적절성이 부족하거나 수집 과정 설명이 미흡함.	15
	분석 주제가 모호하거나 데이터 수집이 부분적으로 이루어짐.	10
	분석 주제를 설정하지 못하거나 데이터를 수집하지 못함.	5
데이터 정리 및 분석하기 (25점)	데이터를 정리한 후 평균, 비율, 비교 분석 등 2가지 이상의 분석 방법을 활용하여 의미 있는 분석 결과를 도출함.	25
	데이터를 정리하고 1가지 분석 방법을 활용하여 분석을 수행함.	20
	데이터 정리는 하였으나 분석 방법이 단순하거나 결과 해석이 부족함.	15
	데이터 정리 또는 분석 과정이 일부만 이루어짐.	10
	데이터 분석이 이루어지지 않음.	5
데이터 시각화 및 결과 해석하기 (25점)	분석 결과를 그래프 또는 표 2개 이상 활용하여 적절하게 시각화하고 데이터 특징을 명확하게 표현함.	25
	그래프 또는 표 1개 이상을 활용하여 분석 결과를 표현함.	20
	시각화는 있으나 데이터 특징이 충분히 드러나지 않음.	15
	시각화 자료가 부적절하거나 일부만 제시됨.	10
	시각화 자료를 제시하지 못함.	5
데이터 분석 보고서 작성 및 표현하기 (25점)	데이터 분석 결과를 근거로 명확한 결론을 제시하고 분석 과정이 체계적으로 정리된 보고서를 작성함.	25
	분석 결과를 설명하고 결론을 제시하였으나 일부 내용이 부족함.	20
	분석 결과 설명은 있으나 결론이 모호하거나 보고서 구성이 부족함.	15
	보고서 내용이 단순하거나 분석 과정 설명이 부족함.	10
	보고서를 제출하지 않거나 내용이 매우 부족함.	5

6 동점자 처리 규정

가. 동점자 처리 방안 및 우선순위

선택	방안명		방안 순위	방안내 순위	최저 배점
0	전체미적용				
	지필/ 수행순		1		
	지필			1	
	수행			2	
0	정기시험순/수행영역순		2		
	(지필) 1차 정기시험			2	
	(지필) 2차 정기시험			1	
	(수행) 데이터 과학 적용 사례 모델 분석하기			4	
	(수행) 데이터 분석 프로젝트			3	
0	정기시험 배점순		3		
	(지필) 1차 정기시험 배점순			2	
	(지필) 2차 정기시험 배점순			1	

나. 배점순의 최저 배점은 높은 배점에서부터 3번째의 배점으로 선택한다.

7 결시자 성적 처리

가. 정기시험 결시자 성적 처리

- 1) 정기시험을 결시한 경우 학교 학업성적관리규정에 따라 기준 고사의 석차에 해당되는 점수를 기준점으로 결시 유형에 따른 인정점을 산출한다.
- 2) 기준 고사에 동점자가 있는 경우 중간석차를 활용한다.
- 3) 기준 고사의 선정
 - 가) 결시자의 다른 정기시험 성적이 있는 경우
 - 응시한 정기시험을 기준 고사로 선정한다.
 - 나) 결시자의 다른 정기시험 성적이 없는 경우
 - (1) 결시자가 응시한 수행평가를 기준 고사로 선정한다.
 - (2) 응시한 수행평가가 2회 이상인 경우 반영비율을 반영한 환산점수를 기준 고사로 선정한다.

나. 수행평가 결시자 성적 처리

- 1) 수행평가를 치를 수 있는 다른 날짜를 제시(2회)하여 탐구 활동을 수행하도록 하고 결과물을 받는다.
- 2) 제시된 다른 날짜에도 수행평가를 치르지 않았을 경우 학교 학업성적관리규정을 준용하여 기준 고사의 석차에 해당되는 점수를 기준점으로 결시 유형에 따른 인정점을 산출한다.
- 3) 기준 고사에 동점자가 있는 경우 중간석차를 활용한다.
- 4) 출석인정결석인 경우 기준점의 100%, 병결석인 경우 기준점의 80%, 미인정 결석, 결과 및 미응시인 경우 미실시자/미제출자에 준하는 점수를 부여한다.
 - * 수행평가 최초 결시와 추가 2회 결시 사유 중 가장 반영비율이 낮은 결시 사유를 적용한다.

5) 기준 고사의 선정

- 가) 결시자의 다른 수행평가 성적이 있는 경우

(1) 결시자가 응시한 수행평가를 기준 고사로 선정한다.

(2) 응시한 수행평가가 2회 이상인 경우 반영비율을 반영한 환산점수를 기준 고사로 선정한다.

나) 결시자의 다른 수행평가 성적이 없는 경우

(1) 결시자가 응시한 정기시험을 기준 고사로 선정한다.

(2) 반영되는 성적은 2차, 1차 순으로 한다.

6) 전입생 및 학적 변동자 인정점부여

가) 학적 변동 전의 수행평가는 출석인정결석에 준하여 인정점을 부여한다.

나) 전입 당시 원적교에서 수행 평가를 실시한 경우 원적교의 원점수를 그대로 인정한다.

다. 위에 해당되지 않는 예외적인 사례가 있을 경우에는 학업성적관리위원회에서 결정한다.

8 성취기준별 성취수준, 학기단위 성취수준

가. 성취기준별 성취수준

(1) 데이터 과학의 이해

성취기준	성취기준별 성취수준	
[12데과01-01] 데이터 과학의 개념을 이해하고, 문제해결 사례를 데이터 기반 의사결정 상황에 적용한다.	A	실제 사례와 활용 분야를 바탕으로 데이터 과학의 개념을 정확하게 설명하고, 데이터 과학 문제해결 사례를 다양하게 탐색하여 데이터 기반 의사결정의 중요성을 내면화하여 표현할 수 있다.
	B	실제 사례와 활용 분야를 바탕으로 데이터 과학의 개념을 정확하게 설명하고, 데이터 과학 문제해결 사례를 탐색하여 데이터 기반 의사결정의 중요성을 인식할 수 있다.
	C	데이터 과학의 개념을 설명하고, 데이터 과학 문제해결 사례를 탐색하여 데이터 기반 의사결정의 중요성을 인식할 수 있다.
	D	데이터 과학의 개념을 설명하고, 데이터 과학 문제해결 사례를 부분적으로 탐색하여 데이터 기반 의사결정의 중요성을 수용할 수 있다.
	E	데이터 과학의 개념을 인지하고 데이터 과학 문제해결 사례를 부분적으로 탐색할 수 있다.
[12데과01-02] 정형 데이터와 비정형 데이터를 구분하고, 데이터 속성에서 데이터의 잠재적 가치를 파악한다.	A	데이터의 형태와 속성을 정확하게 설명하고, 정형 데이터와 비정형 데이터를 정확하게 구분하며 데이터의 속성별 의미와 속성 간 관계를 정확하게 파악하여 수집 데이터의 잠재적 가치를 내면화하여 표현할 수 있다.
	B	데이터의 형태와 속성을 정확하게 설명하고, 정형 데이터와 비정형 데이터를 구분하며 데이터의 속성별 의미와 속성 간 관계를 파악하여 수집 데이터의 잠재적 가치를 인식할 수 있다.
	C	데이터의 형태와 속성을 설명하고, 정형 데이터와 비정형 데이터를 구분하며 데이터의 속성별 의미와 속성 간 관계를 파악하여 수집 데이터의 잠재적 가치를 인식할 수 있다.
	D	데이터의 형태와 속성을 설명하고, 데이터별 형태와 속성을 일부 파악하여 수집 데이터의 잠재적 가치를 수용할 수 있다.
	E	데이터의 형태와 속성을 인지하고, 데이터별 형태와 속성을 일부 파악할 수 있다.
[12데과01-03] 데이터셋의 집합인 데이터베이스를 이해하고, 서로 다른 셋의 데이터를 분석이 가능한 형태로 통합하는 것의 의미를 파악한다.	A	데이터셋과 데이터베이스의 개념을 정확하게 설명하고, 데이터 통합이 필요한 상황과 데이터 통합의 의미를 파악할 수 있다.
	B	데이터셋과 데이터베이스의 개념을 정확하게 설명하고, 데이터 통합의 의미를 파악할 수 있다.
	C	데이터셋과 데이터베이스의 개념을 설명하고, 데이터 통합의 의미를 파악할 수 있다.
	D	데이터셋과 데이터베이스의 개념을 설명하고, 데이터 통합의 의미를 부분적으로 파악할 수 있다.
	E	데이터셋과 데이터베이스의 개념을 인지하고, 데이터 통합의 의미를 부분적으로 파악할 수 있다.
[12데과01-04] 데이터로 인한 사회 변화를 인식하고, 진로 및 직업과 관련한 데이터 기반 문제해결 사례를 분석한다.	A	진로 및 직업과 관련한 데이터 기반 문제해결 사례를 탐색함으로써 데이터로 인한 사회 변화를 다양하게 제시하고, 데이터 과학을 통한 진로설계에 능동적으로 참여할 수 있다.
	B	진로 및 직업과 관련한 데이터 기반 문제해결 사례를 탐색함으로써 데이터로 인한 사회 변화를 다양하게 제시하고, 데이터 과학을 통한 진로설계에 참여할 수 있다.
	C	진로 및 직업과 관련한 데이터 기반 문제해결 사례를 탐색함으로써 데이터로 인한 사회 변화를 제시하고, 데이터 과학을 통한 진로설계에 참여할 수 있다.
	D	진로 및 직업과 관련하여 주어진 데이터 기반 문제해결 사례를 바탕으로 데이터로 인한 사회 변화를 인식하고, 데이터 과학을 통한 진로설계 필요성을 수용할 수 있다.
	E	진로 및 직업과 관련하여 주어진 데이터 기반 문제해결 사례를 바탕으로 데이터로 인한 사회 변화를 인식할 수 있다.

(2) 데이터 준비와 분석

성취기준	성취기준별 성취수준	
[12데과02-01] 데이터를 편향되지 않도록 수집하고, 수집된 데이터의 특성을 분석한다.	A	데이터가 편향되지 않도록 수집하는 적극적인 자세를 갖추고, 수집된 데이터의 특성을 다양한 관점으로 분석할 수 있다.
	B	데이터가 편향되지 않도록 수집하는 자세를 갖추고, 수집된 데이터의 특성을 다양한 관점으로 분석할 수 있다.
	C	데이터가 편향되지 않도록 수집하는 자세를 갖추고, 수집된 데이터의 특성을 분석할 수 있다.
	D	데이터 편향 방지의 필요성을 수용하고, 수집된 데이터의 특성을 분석할 수 있다.
	E	데이터 편향 방지의 필요성을 수용하고, 수집된 데이터의 특성을 일부 분석할 수 있다.
[12데과02-02] 이상치와 결측치 탐색 및 정규화를 통해 전처리하여 오류 가능성을 최소화하고, 데이터 분석을 위해 시각화한다.	A	데이터 전처리의 필요성과 방법을 정확하게 제시하고, 데이터 특성에 맞는 시각화, 이상치와 결측치 탐색 및 처리, 정규화의 적절한 활용을 통해 데이터의 불확실성과 오류 가능성을 내면화하여 표현할 수 있다.
	B	데이터 전처리의 필요성과 방법을 정확하게 제시하고, 데이터 시각화, 이상치와 결측치 처리, 정규화의 활용을 통해 데이터의 불확실성과 오류 가능성을 인식할 수 있다.
	C	데이터 전처리의 필요성과 방법을 제시하고, 데이터 시각화, 이상치와 결측치 처리, 정규화의 활용을 통해 데이터의 불확실성과 오류 가능성을 인식할 수 있다.
	D	데이터 전처리의 필요성과 방법을 제시하고, 일부 데이터 시각화, 이상치 또는 결측치 처리를 통해 데이터의 불확실성과 오류 가능성을 수용할 수 있다.
	E	데이터 전처리의 필요성과 방법을 제시하고, 일부 데이터 시각화, 이상치 또는 결측치 처리를 할 수 있다.
[12데과02-03] 데이터를 분석하기 위해 데이터 속성 간의 관계를 파악하고 통합한다.	A	데이터 분석 목적에 적합한 데이터 속성을 구분하고, 데이터 속성 간의 관계를 파악하고 통합할 수 있다.
	B	데이터 분석 목적에 적합한 데이터 속성을 구분하고, 데이터 속성 간의 관계를 파악할 수 있다.
	C	데이터 속성을 구분하고, 데이터 속성 간의 관계를 파악할 수 있다.
	D	데이터 속성을 구분하고, 데이터 속성 간의 관계를 일부 파악할 수 있다.
	E	데이터 속성을 인지하고, 데이터 속성 간의 관계를 일부 파악할 수 있다.
[12데과02-04] 동일한 데이터를 서로 다른 분석 방법을 적용하여 분석 결과를 비교한다.	A	합리적인 데이터 분석 방법을 다양하게 제시할 수 있으며, 동일한 데이터에 서로 다른 데이터 분석 방법을 적용하고 분석 결과를 비교할 수 있다.
	B	합리적인 데이터 분석 방법을 다양하게 제시할 수 있으며, 동일한 데이터에 적용 가능한 서로 다른 데이터 분석 방법을 비교할 수 있다.
	C	데이터 분석 방법을 다양하게 제시할 수 있으며, 동일한 데이터에 적용 가능한 서로 다른 데이터 분석 방법을 비교할 수 있다.
	D	데이터 분석 방법을 다양하게 제시할 수 있으며, 동일한 데이터에 적용 가능한 서로 다른 데이터 분석 방법을 부분적으로 비교할 수 있다.
	E	동일한 데이터에 적용 가능한 서로 다른 데이터 분석 방법을 인지할 수 있다.

(3) 데이터 모델링과 평가

성취기준	성취기준별 성취수준	
[12데과03-01] 데이터 모델 개념을 이해하고 데이터 분석에 활용할 수 있는 도구를 탐색한다.	A	데이터 모델의 개념을 정확하게 설명하고, 데이터 분석을 위한 도구를 다양하게 탐색할 수 있다.
	B	데이터 모델의 개념을 정확하게 설명하고, 데이터 분석을 위한 도구를 탐색할 수 있다.
	C	데이터 모델의 개념을 설명하고, 데이터 분석을 위한 도구를 탐색할 수 있다.
	D	데이터 모델의 개념을 설명하고, 데이터 분석을 위한 도구를 부분적으로 탐색할 수 있다.
	E	데이터 모델의 개념을 인지하고, 데이터 분석을 위한 도구를 부분적으로 탐색할 수 있다.
[12데과03-02] 동일한 데이터를 통계적 회귀모델과 기계학습을 통한 회귀모델로 분석하여 결과 해석 내용을 비교한다.	A	회귀 분석의 개념을 정확하게 설명하고, 동일한 데이터를 통계적 회귀모델과 기계학습 기반 회귀모델로 분석한 후 분석 결과에 대한 의미를 비판적으로 해석할 수 있다.
	B	회귀 분석의 개념을 정확하게 설명하고, 동일한 데이터를 통계적 회귀모델과 기계학습 기반 회귀모델로 분석한 후 분석 결과에 대한 의미를 해석할 수 있다.
	C	회귀 분석의 개념을 설명하고, 동일한 데이터를 통계적 회귀모델과 기계학습 기반 회귀모델로 분석한 후 분석 결과에 대한 의미를 해석할 수 있다.
	D	회귀 분석의 개념을 설명하고, 동일한 데이터를 통계적 회귀모델과 기계학습 기반 회귀모델로 분석한 결과에 대한 의미를 부분적으로 해석할 수 있다.
	E	회귀 분석의 개념을 인지하고, 동일한 데이터를 통계적 회귀모델과 기계학습 기반 회귀모델로 분석한 결과에 대한 의미를 부분적으로 해석할 수 있다.
[12데과03-03] 데이터의 속성에 대한 유사성을 측정하고 분석하여 군집을 형성하고, 군집 분석 결과의 의미를 해석한다.	A	군집 분석의 개념을 정확하게 설명하고, 데이터의 여러 속성에 대한 유사성을 바탕으로 군집을 형성한 후 분석 결과에 대한 의미를 비판적으로 해석할 수 있다.
	B	군집 분석의 개념을 정확하게 설명하고, 데이터의 여러 속성에 대한 유사성을 바탕으로 군집을 형성한 후 분석 결과에 대한 의미를 해석할 수 있다.
	C	군집 분석의 개념을 설명하고, 데이터의 여러 속성에 대한 유사성을 바탕으로 군집을 형성한 후 분석 결과에 대한 의미를 해석할 수 있다.
	D	군집 분석의 개념을 설명하고, 데이터의 여러 속성에 대한 유사성을 바탕으로 군집을 형성한 후 분석 결과에 대한 의미를 부분적으로 해석할 수 있다.
	E	군집 분석의 개념을 인지하고, 데이터의 여러 속성에 대한 유사성을 바탕으로 군집을 형성한 후 분석 결과에 대한 의미를 부분적으로 해석할 수 있다.
[12데과03-04] 데이터 간의 관계를 분석하고 상호 연관성을 파악하여 결과의 의미를 해석한다.	A	연관 분석의 개념을 정확하게 설명하고, 데이터 간의 관계를 분석하여 상호 연관성을 파악한 후 분석 결과에 대한 의미를 비판적으로 해석할 수 있다.
	B	연관 분석의 개념을 정확하게 설명하고, 데이터 간의 관계를 분석하여 상호 연관성을 파악한 후 분석 결과에 대한 의미를 해석할 수 있다.
	C	연관 분석의 개념을 설명하고, 데이터 간의 관계를 분석하여 상호 연관성을 파악한 후 분석 결과에 대한 의미를 해석할 수 있다.
	D	연관 분석의 개념을 설명하고, 데이터 간의 관계를 분석하여 상호 연관성을 파악한 후 분석 결과에 대한 의미를 부분적으로 해석할 수 있다.
	E	연관 분석의 개념을 인지하고, 데이터 간의 관계를 분석하여 상호 연관성을 파악한 후 분석 결과에 대한 의미를 부분적으로 해석할 수 있다.
[12데과03-05] 데이터 분석 방법에 따른 데이터 모델의 분석 결과를 비교하고 평가하여 데이터에 대한 다양한 해석을 제시하고 비판적으로 수용할 수 있다.	A	여러 가지 데이터 분석 방법에 따른 데이터 모델의 분석 결과를 비교하고 평가하여 데이터에 대한 다양한 해석을 제시하고 비판적으로 수용할 수 있다.
	B	여러 가지 데이터 분석 방법에 따른 데이터 모델의 분석 결과를 비교하고 평가하여 데이터에 대한 다양한 해석을 비판적으로 수용할 수 있다.
	C	데이터 분석 방법에 따른 데이터 모델의 분석 결과를 평가하여 데이터에 대한 다양한 해석을 비판적으로 수용할 수 있다.
	D	데이터 분석 방법에 따른 데이터 모델의 분석 결과를 평가하여 데이터에 대한 해석을 수용할 수 있다.
	E	데이터 분석 방법에 따른 데이터 모델의 분석 결과를 부분적으로 평가하여 데이터에 대한 해석을 수용할 수 있다.

성취기준	성취기준별 성취수준	
[12데과03-06] 다양한 분석 방법을 비교하고 평가하여 분석 목적에 가장 적합한 분석 방법을 적용한다.	A	다양한 분석 방법을 성능, 효율성 등 여러 기준으로 비교하고 평가하며, 적절한 분석 방법을 선택하여 적용하는 자세를 내면화하여 표현할 수 있다.
	B	다양한 분석 방법을 성능, 효율성 등 여러 기준으로 비교하고 평가하며, 적절한 분석 방법을 선택하여 적용하는 자세의 중요성을 인식할 수 있다.
	C	다양한 분석 방법을 비교하고 평가하며, 적절한 분석 방법을 선택하여 적용하는 자세의 중요성을 인식할 수 있다.
	D	다양한 분석 방법을 비교하고 평가하며, 적절한 분석 방법을 선택하여 적용하는 자세를 수용할 수 있다.
	E	다양한 분석 방법을 비교하고, 적절한 분석 방법을 선택하여 적용하는 자세를 수용할 수 있다.

(4) 데이터 과학 프로젝트

성취기준	성취기준별 성취수준	
[12데과04-01] 분야별 데이터 과학의 적용 사례를 조사하여 분석하고, 데이터로 해결 가능한 주제를 찾아 적합성을 판단한다.	A	분야별 데이터 과학의 주제를 다양하게 조사하며, 데이터로 해결 가능한 주제를 정확하게 설명하고 적합성을 판단할 수 있다.
	B	분야별 데이터 과학의 주제를 조사하며, 데이터로 해결 가능한 주제를 정확하게 설명하고 적합성을 판단할 수 있다.
	C	분야별 데이터 과학의 주제를 조사하며, 데이터로 해결 가능한 주제를 설명할 수 있다.
	D	데이터 과학의 주제를 조사하며, 데이터로 해결 가능한 주제를 설명할 수 있다.
	E	데이터 과학의 주제를 조사하고, 데이터로 해결 가능한 주제를 인지할 수 있다.
[12데과04-02] 수집된 데이터를 탐색적으로 분석하여 데이터 속 의미를 파악하고, 문제해결을 위한 창의적인 방법을 구상한다.	A	탐색적 데이터 분석을 정확하게 설명하고, 탐색적 데이터 분석으로 데이터 속 의미를 다각도로 파악함으로써 문제를 해결하기 위한 창의적인 방법을 고민하는 자세를 내면화하여 표현할 수 있다.
	B	탐색적 데이터 분석을 정확하게 설명하고, 탐색적 데이터 분석으로 데이터 속 의미를 파악함으로써 문제를 해결하기 위한 창의적인 방법을 고민하는 자세를 인식할 수 있다.
	C	탐색적 데이터 분석을 설명하고, 탐색적 데이터 분석으로 데이터 속 의미를 파악함으로써 문제를 해결하기 위한 창의적인 방법을 고민하는 자세를 인식할 수 있다.
	D	탐색적 데이터 분석을 설명하고, 탐색적 데이터 분석으로 데이터 속 의미를 부분적으로 파악함으로써 문제를 해결하기 위한 창의적인 방법을 고민하는 자세를 수용할 수 있다.
	E	탐색적 데이터 분석을 인지하고, 탐색적 데이터 분석으로 데이터 속 의미를 부분적으로 파악할 수 있다.
[12데과04-03] 데이터 분석을 진행할 때, 2개 이상의 방법을 사용하여 분석하고 결과를 비교한다.	A	동일한 데이터를 기반으로 서로 다른 데이터 분석 방법을 적용한 결과를 다각도로 비교하고, 가장 적절한 데이터 모델링 방법을 설계하는 자세를 내면화하여 표현할 수 있다.
	B	동일한 데이터를 기반으로 서로 다른 데이터 분석 방법을 적용한 결과를 다각도로 비교하고, 적절한 데이터 모델링 방법을 설계하는 자세를 인식할 수 있다.
	C	동일한 데이터를 기반으로 서로 다른 데이터 분석 방법을 적용한 결과를 비교하고, 적절한 데이터 모델링 방법을 설계하는 자세를 인식할 수 있다.
	D	동일한 데이터를 기반으로 서로 다른 데이터 분석 방법을 적용한 결과를 비교하고, 적절한 데이터 모델링 방법을 설계하는 자세를 수용할 수 있다.
	E	동일한 데이터를 기반으로 서로 다른 데이터 분석 방법을 적용한 결과를 부분적으로 비교할 수 있다.

성취기준	성취기준별 성취수준	
[12데과04-04] 복잡하고 어려운 문제라도 끝까지 해결하기 위한 자세를 갖추고 분석하여, 분석 결과에 대한 의미를 해석한다.	A	분석 결과에 대한 의미를 비판적으로 해석하고, 복잡하고 어려운 문제를 끝까지 해결하기 위해 노력하는 태도를 내면화하여 표현할 수 있다.
	B	분석 결과에 대한 의미를 비판적으로 해석하고, 복잡하고 어려운 문제를 끝까지 해결하기 위해 노력하는 태도를 인식할 수 있다.
	C	분석 결과에 대한 의미를 해석하고, 복잡하고 어려운 문제를 끝까지 해결하기 위해 노력하는 태도를 인식할 수 있다.
	D	분석 결과에 대한 의미를 해석하고, 복잡하고 어려운 문제를 끝까지 해결하기 위해 노력하는 태도를 수용할 수 있다.
	E	분석 결과에 대한 의미를 일부 해석하고, 복잡하고 어려운 문제를 끝까지 해결하기 위해 노력하는 태도를 수용할 수 있다.
[12데과04-05] 분석을 위한 목적부터 데이터 수집 및 분석에 이르는 전 과정을 성찰하고, 사회적 영향을 고려하여 분석 결과의 활용방안을 탐색한다.	A	사회적 영향을 고려하여 분석 결과를 활용하는 방법을 다양하게 탐색하고, 일반화 및 공유 과정에서 윤리 문제 등 사회적 영향을 인식하는 자세를 내면화하여 표현할 수 있다.
	B	사회적 영향을 고려하여 분석 결과를 활용하는 방법을 다양하게 탐색하고, 일반화 및 공유 과정에서 윤리 문제 등 사회적 영향을 인식하는 자세를 수용할 수 있다.
	C	사회적 영향을 고려하여 분석 결과를 활용하는 방법을 탐색하고, 일반화 및 공유 과정에서 윤리 문제 등 사회적 영향을 인식하는 자세를 수용할 수 있다.
	D	사회적 영향을 고려하여 분석 결과를 활용하는 방법을 부분적으로 탐색하고, 일반화 및 공유 과정에서 윤리 문제 등 사회적 영향을 인식하는 자세를 수용할 수 있다.
	E	사회적 영향을 고려하여 분석 결과를 활용하는 방법을 부분적으로 탐색할 수 있다.

나. 학기단위 성취수준

A	데이터 과학의 개념, 데이터의 형태와 속성, 데이터셋과 데이터베이스의 개념을 정확하게 설명할 수 있다. 데이터 과학 문제해결 사례를 다양하게 탐색하고, 데이터의 형태와 속성, 데이터 통합이 필요한 상황과 데이터 통합의 의미를 정확하게 파악하며, 진로 및 직업과 관련한 데이터 과학의 문제해결 사례를 탐색함으로써 데이터로 인한 사회 변화를 다양하게 제시할 수 있다. 데이터 기반 의사결정의 중요성과 데이터의 잠재적 가치를 내면화하고, 데이터 과학을 통한 진로설계에 능동적으로 참여할 수 있다. 데이터 전처리의 필요성을 정확하게 설명하고 데이터 분석 목적에 맞는 데이터 속성을 분별하며, 여러 합리적인 데이터 분석 방법을 제시할 수 있다. 데이터의 특성을 다양한 관점으로 분석하고 데이터 특성에 맞는 시각화, 이상치와 결측치 탐색 및 처리, 정규화를 하며, 데이터 속성 간의 관계를 파악 및 통합하고 서로 다른 데이터 분석 방법을 적용한 후 분석 결과를 비교할 수 있다. 데이터가 편향되지 않도록 수집하는 적극적인 자세와 데이터의 불확실성과 오류 가능성을 내면화할 수 있다. 데이터 모델의 개념, 회귀 분석, 군집 분석, 연관 분석을 정확하게 설명할 수 있다. 데이터 분석을 위한 도구를 다양하게 탐색하고 데이터 모델의 분석 결과에 대한 의미를 비판적으로 해석하며, 여러 가지 데이터 분석 방법에 따른 분석 결과를 종합적으로 비교하고 평가할 수 있다. 데이터에 대한 다양한 해석을 제시하고 비판적으로 수용하며, 적절한 분석 방법을 선택하여 적용하는 자세를 내면화할 수 있다. 데이터로 해결이 가능한 주제, 탐색적 데이터 분석을 정확하게 설명하고, 분석 결과에 대한 의미를 비판적으로 해석할 수 있다. 분야별 데이터 과학의 주제를 다양하게 조사하고 탐색적 데이터 분석으로 데이터 속 의미를 다각도로 파악하며, 서로 다른 데이터 분석 방법을 적용한 결과를 비교하고 분석 결과를 활용하는 방법을 다양하게 탐색할 수 있다. 문제를 해결하기 위한 창의적인 방법을 고민하는 자세, 가장 적절한 데이터 모델링 방법을 설계하는 자세, 복잡하고 어려운 문제를 끝까지 해결하기 위해 노력하는 태도, 일반화 및 공유 과정에서 윤리 문제 등 사회적 영향을 인식하는 자세를 내면화할 수 있다.
---	---

B	데이터 과학의 개념을 정확하게 설명하고, 데이터의 형태와 속성, 데이터셋과 데이터베이스의 개념을 설명할 수 있다. 데이터 과학 문제해결 사례를 다양하게 탐색하고, 데이터의 형태와 속성, 데이터 통합이 필요한 상황과 데이터 통합의 의미를 정확하게 파악하며, 진로 및 직업과 관련한 데이터 과학의 문제해결 사례를 탐색함으로써 데이터로 인한 사회 변화를 제시할 수 있다. 데이터 기반 의사결정의 중요성과 데이터의 잠재적 가치를 내면화하고, 데이터 과학을 통한 진로설계에 참여할 수 있다. 데이터 전처리의 필요성을 정확하게 설명하고 데이터 속성을 분별하며, 여러 데이터 분석 방법을 제시할 수 있다. 데이터의 특성을 다양한 관점으로 분석하고 데이터 특성에 맞는 시각화, 이상치와 결측치 탐색 및 처리, 정규화를 하며, 데이터 속성 간의 관계를 파악하고 서로 다른 데이터 분석 방법을 비교할 수 있다. 데이터가 편향되지 않도록 수집하는 적극적인 자세를 갖추고 데이터의 불확실성과 오류 가능성을 인식할 수 있다. 데이터 모델의 개념을 정확하게 설명하고, 회귀 분석, 군집 분석, 연관 분석을 설명할 수 있다. 데이터 분석을 위한 도구를 다양하게 탐색하고 데이터 모델의 분석 결과에 대한 의미를 비판적으로 해석하며, 여러 가지 데이터 분석 방법에 따른 분석 결과를 비교하고 평가할 수 있다. 데이터에 대한 다양한 해석을 제시하고 비판적으로 수용하며, 적절한 분석 방법을 선택하여 적용하는 자세의 중요성을 인식할 수 있다. 데이터로 해결이 가능한 주제, 탐색적 데이터 분석을 정확하게 설명하고, 분석 결과에 대한 의미를 해석할 수 있다. 분야별 데이터 과학의 주제를 다양하게 조사하고 탐색적 데이터 분석으로 데이터 속 의미를 다각도로 파악하며, 서로 다른 데이터 분석 방법을 적용한 결과를 비교하고 분석 결과를 활용하는 방법을 탐색할 수 있다. 문제를 해결하기 위한 창의적인 방법을 고민하는 자세, 가장 적절한 데이터 모델링 방법을 설계하는 자세를 내면화하고, 복잡하고 어려운 문제를 끝까지 해결하기 위해 노력하는 태도, 일반화 및 공유 과정에서 윤리 문제 등 사회적 영향을 인식하는 자세를 인식할 수 있다.
C	데이터 과학의 개념, 데이터의 형태와 속성, 데이터셋과 데이터베이스의 개념을 설명할 수 있다. 데이터 과학 문제해결 사례를 탐색하고, 데이터의 형태와 속성, 데이터 통합이 필요한 상황과 데이터 통합의 의미를 파악하며, 진로 및 직업과 관련한 데이터 과학의 문제해결 사례를 탐색함으로써 데이터로 인한 사회 변화를 제시할 수 있다. 데이터 기반 의사결정의 중요성과 데이터의 잠재적 가치를 인식하고, 데이터 과학을 통한 진로설계에 참여할 수 있다. 데이터 전처리의 필요성을 설명하고 데이터 속성을 분별하며, 여러 데이터 분석 방법을 제시할 수 있다. 데이터의 특성을 분석하고 데이터 시각화, 이상치와 결측치 탐색 및 처리, 정규화를 하며, 데이터 속성 간의 관계를 파악하고 서로 다른 데이터 분석 방법을 비교할 수 있다. 데이터가 편향 방지의 필요성, 데이터의 불확실성과 오류 가능성을 인식할 수 있다. 데이터 모델의 개념, 회귀 분석, 군집 분석, 연관 분석을 설명할 수 있다. 데이터 분석을 위한 도구를 탐색하고 데이터 모델의 분석 결과에 대한 의미를 해석하며, 데이터 분석 방법에 따른 분석 결과를 비교하고 평가할 수 있다. 데이터에 대한 다양한 해석을 비판적으로 수용하며, 적절한 분석 방법을 선택하여 적용하는 자세의 중요성을 인식할 수 있다. 데이터로 해결이 가능한 주제, 탐색적 데이터 분석을 설명하고, 분석 결과에 대한 의미를 해석할 수 있다. 분야별 데이터 과학의 주제를 조사하고 탐색적 데이터 분석으로 데이터 속 의미를 파악하며, 서로 다른 데이터 분석 방법을 적용한 결과를 비교하고 분석 결과를 활용하는 방법을 탐색할 수 있다. 문제를 해결하기 위한 창의적인 방법을 고민하는 자세, 가장 적절한 데이터 모델링 방법을 설계하는 자세, 복잡하고 어려운 문제를 끝까지 해결하기 위해 노력하는 태도, 일반화 및 공유 과정에서 윤리 문제 등 사회적 영향을 인식하는 자세를 인식할 수 있다.
D	데이터 과학의 개념을 설명하고, 데이터의 형태와 속성, 데이터셋과 데이터베이스의 개념을 인지할 수 있다. 데이터 과학 문제해결 사례를 탐색하고, 데이터의 형태와 속성, 데이터 통합이 필요한 상황과 데이터 통합의 의미를 파악하며, 진로 및 직업과 관련한 데이터 과학의 문제해결 사례를 탐색함으로써 데이터로 인한 사회 변화를 인식할 수 있다. 데이터 기반 의사결정의 중요성과 데이터의 잠재적 가치를 인식하고, 데이터 과학을 통한 진로설계의 필요성을 수용할 수 있다. 데이터 전처리의 필요성을 설명하고, 데이터 속성과 여러 데이터 분석 방법을 인지할 수 있다. 데이터의 특성을 분석하고 데이터 시각화, 이상치와 결측치 탐색 및 처리, 정규화를 하며, 데이터 속성 간의 관계를 일부 파악하며 서로 다른 데이터 분석 방법을 부분적으로 비교할 수 있다. 데이터가 편향 방지의 필요성을 인식하고, 데이터의 불확실성과 오류 가능성을 수용할 수 있다. 데이터 모델의 개념을 설명하고, 회귀 분석, 군집 분석, 연관 분석을 인지할 수 있다. 데이터 분석을 위한 도구를 탐색하고 데이터 모델의 분석 결과에 대한 의미를 일부 해석하며, 여러 가지 데이터 분석 방법에 따른 분석 결과를 부분적으로 비교하고 평가할 수 있다. 데이터에 대한 다양한 해석, 적절한 분석 방법을 선택하여 적용하는 자세를 수용할 수 있다. 데이터로 해결이 가능한 주제, 탐색적 데이터 분석을 설명하고, 분석 결과에 대한 의미를 부분적으로 해석할 수 있다. 분야별 데이터 과학의 주제를 조사하고 탐색적 데이터 분석으로 데이터 속 의미를 파악하며, 서로 다른 데이터 분석 방법을 적용한 결과를 일부 비교하고 분석 결과를 활용하는 방법을 부분적으로 탐색할 수 있다. 문제를 해결하기 위한 창의적인 방법을 고민하는 자세, 가장 적절한 데이터 모델링 방법을 설계하는 자세를 인식하고, 복잡하고 어려운 문제를 끝까지 해결하기 위해 노력하는 태도, 일반화 및 공유 과정에서 윤리 문제 등 사회적 영향을 인식하는 자세를 수용할 수 있다.
E	데이터 과학의 개념, 데이터의 형태와 속성, 데이터셋과 데이터베이스의 개념을 인지할 수 있다. 데이터 과학 문제해결 사례를 일부 탐색하고, 데이터의 형태와 속성, 데이터 통합이 필요한 상황과 데이터 통합의 의미를 부분적으로 파악하며, 진로 및 직업과 관련한 데이터 과학의 문제해결 사례를 탐색함으로써 데이터로 인한 사회 변화를 인식할 수 있다. 데이터 기반 의사결정의 중요성, 데이터의 잠재적 가치, 데이터 과학을 통한 진로설계의 필요성을 수용할 수 있다. 데이터 전처리의 필요성, 데이터 속성, 여러 데이터 분석 방법을 인지할 수 있다. 데이터의 특성을 부분적으로 분석하고, 데이터 속성 간의 관계를 일부 파악하며 서로 다른 데이터 분석 방법을 부분적으로 비교할 수 있다. 데이터가 편향 방지의 필요성, 데이터의 불확실성과 오류 가능성을 수용할 수 있다. 데이터 모델의 개념, 회귀 분석, 군집 분석, 연관 분석을 인지할 수 있다. 데이터 분석을 위한 도구를 부분적으로 탐색하고 데이터 모델의 분석 결과에 대한 의미를 일부 해석하며, 데이터 분석 방법에 따른 분석 결과를 부분적으로 비교하고 평가할 수 있다. 데이터에 대한 해석, 적절한 분석 방법을 선택하여 적용하는 자세를 수용할 수 있다. 데이터로 해결이 가능한 주제, 탐색적 데이터 분석을 인지하고, 분석 결과에 대한 의미를 부분적으로 해석할 수 있다. 데이터 과학의 주제를 조사하고 탐색적 데이터 분석으로 데이터 속 의미를 부분적으로 파악하며, 서로 다른 데이터 분석 방법을 적용한 결과를 일부 비교하고 분석 결과를 활용하는 방법을 부분적으로 탐색할 수 있다. 문제를 해결하기 위한 창의적인 방법을 고민하는 자세, 적절한 데이터 모델링 방법을 설계하는 자세, 복잡하고 어려운 문제를 끝까지 해결하기 위해 노력하는 태도를 수용할 수 있다.

III 데이터 모델링과 평가

이 단원에서는

- 데이터 모델의 개념을 이해하고 회귀분석, 군집 분석, 연관분석을 학습한 후, 분석도구를 활용하여 데이터를 분석하고 새로운 지식을 추출할 수 있다.
- 분석 결과를 평가하고 그 의미를 해석함으로써 보편적 사고를 가질 수 있다.
- 다양한 분석 방법을 검토하여 적절한 방법을 선택하는 능력을 키우고, 유연하게 문제를 해결하는 태도를 함양할 수 있다.

1

데이터 모델과 회귀분석

데이터 모델과 회귀분석을 통해 어떻게 데이터를 분석하여 문제를 해결할 수 있을까?

2

군집 분석과 연관분석

데이터에 명확한 레이블이 주어지지 않았을 때 우리는 데이터를 어떻게 분석할 수 있을까?

1. 데이터 모델과 회귀분석 | 122p

1. 데이터 모델과 회귀분석

Q

데이터 모델과 회귀분석을 통해 어떻게 데이터를 분석하여 문제를 해결할 수 있을까?

A

데이터의 패턴을 분석하고 변수 간의 관계를 모델링한 후 예측과 의사 결정을 위한 해결책을 도출한다.

1. 데이터 모델과 회귀분석 | 122p

1. 데이터 모델과 회귀분석

점검해 보기

다음 설명 내용에 알맞은 용어를 선으로 연결해 보자.

설명		용어
1. 명확하게 구별된 값의 범주나 개별 항목으로 구분	✗	연속적인 값
2. 일정 범위 내에서 어떤 값이든 취할 수 있는 수치	✗	이산적인 값
3. 예측 변수, 결과 변수, 출력 변수	✗	독립 변수
4. 종속 변수에 영향을 주는 변수, 예측에 사용되는 입력 변수	✗	종속 변수

1. 데이터 모델과 회귀분석 | 122p

세상을 바꾸는 데이터

아이스크림 가게 냉장고의 비밀

“오늘도 장사 성공이야!”

북교등학교 앞에서 아이스크림 가게를 운영하는 ○○ 씨는 학생들이 좋아하는 연예인 광고 포스터를 문 앞에 붙였다. 그리고 TV에서 일기예보를 본 후 주문 시스템에서 △△ 아이스크림의 수량을 2배로 늘려 주문하였다.




1. 데이터 모델과 회귀분석 | 122p

세상을 바꾸는 데이터

아이스크림 가게 냉장고의 비밀

○○ 씨는 위 세 가지의 데이터를 기반으로 학생들이 아이스크림을 많이 구매할 것이라고 판단했고, 그 결과는 성공적이었다. 다시 말해, ○○ 씨 가게의 매출은 날씨, 광고(연예인), 지리적 요건(학교 앞)이라는 여러 변수 간의 관계를 회귀분석으로 설명할 수 있다. 이를 통해 변수 간의 상관관계를 분석하여 매출이 결정된 것이다.



1. 데이터 모델과 회귀분석 | 123p

세상을 바꾸는 데이터

아이스크림 가게 냉장고의 비밀

회귀분석으로 얻은 데이터는 단순히 과거의 성과를 분석하는 데 그치지 않고, 미래 판매를 예측하고 마케팅 전략을 최적화하며, 최종적으로는 아이스크림 판매량을 극대화하는 데 중요한 역할을 한다.



1-1

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 124p

데이터 모델

👉 학습 목표

- 데이터 모델 개념을 설명할 수 있다.
- 데이터 분석에 활용 가능한 도구를 탐색할 수 있다.

1-1

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 124p

데이터 모델

데이터 과학은 일상생활에서 경험하는 다양한 현상이나 문제를 이해하고 통찰할 수 있도록 도와준다.

데이터 과학의 중요한 부분 중 하나인 모델링은 데이터를 분석하고 그 결과를 바탕으로 예측하거나 패턴을 찾아내는 과정을 의미한다.

이처럼 데이터 과학의 세계는 다양한 방법과 과정으로 구성되어, 우리의 일상생활에 영향을 미친다.

데이터 모델링과 평가는 문제를 합리적으로 선택하고 새로운 지식을 추출하는 데 도움을 준다. 이를 통해 데이터 기반의 합리적인 결정을 내리는 데 어떻게 도움을 줄 수 있을까?




데이터 과학으로 문제를 바라본다면?

분석하고자 하는 주제에 맞춰 데이터를 수집하고 처리한 후, 이를 적합한 데이터 모델에 적용하면 의미 있는 정보를 발견할 수 있다. 수집한 데이터에 정답(레이블) 데이터가 포함되어 있고, 이를 통해 새롭게 알아내고자 하는 값이 연속형인 경우(예: 이스크림 판매량 예측)에는 회귀분석 모델을 선택하고, 범주형인 경우(예: 합격 여부 예측)에는 분류 모델을 선택한다.



데이터 과학으로 문제를 바라본다면?

반면, 정답 데이터가 포함되어 있지 않은 경우에는 비슷한 특성을 가진 데이터들을 묶어 군집 분석을 하거나, 항목 간 관계를 파악하기 위해 연관분석 모델을 선택하는 등 다양한 상황에 따른 적절한 분석 방법을 선택하는 것이 필요하다.



1 데이터 모델이란 무엇일까?

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 125p

데이터 모델

- 데이터를 이해하고 정보를 추출하는 과정에서 사용되는 다양한 방법이나 기술
- 데이터의 패턴, 관계, 구조 등을 나타내는 것으로 데이터의 특성을 파악하여 예측, 군집, 연관분석 등의 작업을 수행하는 데 활용

1 데이터 모델이란 무엇일까?

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 125p

데이터 모델링

- 데이터에 대한 이해를 토대로 모델을 선택하고 구축하는 과정
- 주어진 데이터와 분석 목적에 따라 적합한 모델을 선택해서 이를 적용하고 결과를 도출해 낼 수 있음

💡 데이터 모델은 주어진 데이터를 해석하고 예측하는 데 사용되는 중요한 방법이며, 적절한 모델을 선택하고 구축하는 데 결정적인 역할을 함

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 125p

1 데이터 모델이란 무엇일까?

표 10-1 데이터 모델의 종류

모델	목적	지표 예시	사례
회귀 분석	연속형 중속 변수를 예측	평균 제곱 오차 (MSE: Mean Squared Error)	부동산 데이터를 바탕으로 집값 예측
군집 분석	비슷한 특성을 가진 그룹 생성	실루엣 계수 (silhouette coefficient)	구매 패턴에 따라 고객 그룹을 나눠 맞춤형 프로모션 제공
연관 분석	데이터 내에서 항목 간의 관계, 연관성을 발견	지지도(support) 신뢰도(confidence) 향상도.lift)	구매 상품을 파악하여 상품 진열 전략 제공

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 125p

1 데이터 모델이란 무엇일까?

- 상황에 맞는 데이터 모델링을 통해 데이터에 숨어 있는 법칙을 찾아 내거나 그룹으로 분류할 수 있고, 미래의 변화를 예측할 수 있음
- 데이터 모델에 따라 사용하는 데이터의 종류와 분석의 목적이 다르 고 분석을 완료한 후에 그 결과를 평가하는 방법도 다름

💡 데이터의 특성과 분석하고자 하는 문제의 본질에 맞는 데이터 모델을 선택해야 함

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 125p

1 데이터 모델이란 무엇일까?

스스로 해결하기

탐구 분석

주어진 문제 상황을 해결하기 위해 적합한 데이터 모델을 적어 보자.

문제 상황	목적	데이터 모델
마트의 거래 데이터를 활용하여 고객들이 상품을 구매할 때 함께 구매하는 상품 파악	상품 진열이나 마케팅 전략 개선	연관 분석
쇼핑몰의 고객 데이터를 활용하여 비슷한 구매 패턴을 보이는 고객 파악	맞춤형 상품 추천	군집 분석
광고 비용과 제품 판매량 간의 관계 분석	광고 예산 최적화 및 효율적인 광고 전략 수립	회귀분석

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 126p

2 데이터 분석 도구에는 무엇이 있을까?

1 노코딩 (no-coding) 도구

노코딩(no-coding) 도구

- 사용자가 프로그래밍 언어를 배우지 않고도 메뉴 클릭 또는 드래그 앤드 드롭 등으로 복잡한 작업을 수행할 수 있도록 도와주는 프로그램
- 데이터 관리, 분석, 시각화 등 다양한 작업을 쉽게 수행할 수 있음

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 126p

2 데이터 분석 도구에는 무엇이 있을까?

1 노코딩 (no-coding) 도구

스프레드시트

- 비전문가들도 사용하기 쉬운 프로그램
- 데이터의 탐색적 분석, 간단한 모델링 등을 수행
- 데이터를 차트, 추세선 등으로 표현하여 시각화
- 차트의 속성 변경 가능




1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 126p

2 데이터 분석 도구에는 무엇이 있을까?

1 노코딩 (no-coding) 도구

오렌지

- 마우스 드래그 앤드 드롭으로 사용할 수 있는 GUI기반 데이터 분석 프로그램
- 위젯을 연결하여 작업을 수행하며, 위젯을 더블 클릭하면 결과 확인 가능



1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 126p

2 데이터 분석 도구에는 무엇이 있을까?

예제 1

노코딩 도구인 스프레드 시트와 오픈지 데이터 분석 도구를 활용하여 동일한 데이터를 시각화해 보자.

데이터: 연도별 사용량으로 2019년(5), 2020년(7), 2021년(6), 2022년(9), 2023년(11)이다.

실습데이터




1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 126p

2 데이터 분석 도구에는 무엇이 있을까?

예제 1

노코딩 도구인 스프레드 시트와 오픈지 데이터 분석 도구를 활용하여 동일한 데이터를 시각화해 보자.

스프레드시트



- ① 데이터를 입력한다.
- ② 차트를 만들어서 시각화한다.
- ③ 차트 요소에서 추세선을 추가한다.


1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 126p

2 데이터 분석 도구에는 무엇이 있을까?

예제 1

노코딩 도구인 스프레드 시트와 오픈지 데이터 분석 도구를 활용하여 동일한 데이터를 시각화해 보자.

오픈지



- ① Data 카테고리에서 'File' 위젯으로 데이터를 불러온다.
- ② 'Data Table' 위젯으로 내용을 확인한다.
- ③ Visualize 카테고리에서 'Scatter Plot' 위젯으로 시각화한다.
 - X축: 연도, Y축: 사용량
 - 'Show regression line' 속성 체크

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 127p

2 데이터 분석 도구에는 무엇이 있을까?

2 코딩 (coding) 도구

코딩(coding) 도구

- 프로그래밍 언어를 사용하여 데이터 분석 및 시각화, 기계학습, 프로그램 개발 등 다양한 작업을 수행할 수 있도록 도와주는 프로그램

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 127p

2 데이터 분석 도구에는 무엇이 있을까?

2 코딩 (coding) 도구

- 파이썬과 R 프로그래밍 언어는 데이터 분석에 유용하게 사용되며, 코딩으로 데이터 분석에서부터 시각화 작업까지 쉽게 수행할 수 있음



파이썬

- 데이터 분석 및 기계학습 분야에서 가장 널리 사용되는 프로그래밍 언어
- Numpy, Pandas, Matplotlib 등과 같은 데이터 분석 및 시각화 라이브러리 제공
- 사용자 컴퓨터에 IDLE, Visual Studio Code와 같은 프로그램을 설치하거나, 온라인 플랫폼인 주피터 노트북, Colab 등을 활용하는 등 다양한 환경에서 작업 가능

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 127p

2 데이터 분석 도구에는 무엇이 있을까?

2 코딩 (coding) 도구

- 파이썬과 R 프로그래밍 언어는 데이터 분석에 유용하게 사용되며, 코딩으로 데이터 분석에서부터 시각화 작업까지 쉽게 수행할 수 있음



R

- 통계 및 데이터 분석에 특화된 프로그래밍 언어
- 풍부한 통계 및 시각화 라이브러리 제공
- R, RStudio 프로그램을 설치하여 사용 가능

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 127p

2 데이터 분석 도구에는 무엇이 있을까?

예제 2

코딩 도구인 파이썬과 R 프로그래밍을 통해 동일한 데이터를 시각화해 보자.

파이썬

```
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm

# 데이터 생성
data = {'year': [2019, 2020, 2021, 2022, 2023],
        'count': [5, 7, 6, 9, 11]}

# 데이터프레임 변환
df = pd.DataFrame(data)
```

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 127p

2 데이터 분석 도구에는 무엇이 있을까?

예제 2

코딩 도구인 파이썬과 R 프로그래밍을 통해 동일한 데이터를 시각화해 보자.

파이썬

```
# x축, y축 설정
x = df['year']
y = df['count']

# 상수항(절편 추가)
x = sm.add_constant(x)

# 선형 회귀 모델 학습
model = sm.OLS(y, x).fit()
```

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 127p

2 데이터 분석 도구에는 무엇이 있을까?

예제 2

코딩 도구인 파이썬과 R 프로그래밍을 통해 동일한 데이터를 시각화해 보자.

파이썬

```
# 시각화
plt.figure(figsize=(5,3))
plt.plot(df['year'], df['count'], marker='o', label='count')
plt.plot(df['year'], model.predict(x), marker='s', label='predict',
         linestyle='--')
plt.title('example')
plt.xlabel('year')
plt.ylabel('count')
plt.xticks(rotation=45)
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 127p

2 데이터 분석 도구에는 무엇이 있을까?

예제 2

코딩 도구인 파이썬과 R 프로그래밍을 통해 동일한 데이터를 시각화해 보자.

파이썬

```
# 시각화
plt.figure(figsize=(5,3))
plt.plot(df['year'], df['count'], marker='o', label='count')
plt.plot(df['year'], model.predict(x), marker='s', label='predict',
         linestyle='--')
plt.title('example')
plt.xlabel('year')
plt.ylabel('count')
plt.xticks(rotation=45)
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 127p

2 데이터 분석 도구에는 무엇이 있을까?

예제 2

코딩 도구인 파이썬과 R 프로그래밍을 통해 동일한 데이터를 시각화해 보자.

R

```
# dplyr 패키지 설치 및 로드
install.packages('dplyr')
library(dplyr)

# lme4 패키지 설치 및 로드
install.packages('lme4')
library(lme4)

# ggplot2 패키지 설치 및 로드
install.packages('ggplot2')
library(ggplot2)
```

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 127p

2 데이터 분석 도구에는 무엇이 있을까?

예제 2

코딩 도구인 파이썬과 R 프로그래밍을 통해 동일한 데이터를 시각화해 보자.

R

```
# 데이터 생성
data <- data.frame(
  year = c(2019, 2020, 2021, 2022, 2023),
  count = c(5, 7, 6, 9, 11)
)
```

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 127p

2 데이터 분석 도구에는 무엇이 있을까?

예제 2

코딩 도구인 파이썬과 R 프로그래밍을 통해 동일한 데이터를 시각화해 보자.

R

```
# 데이터 프레임 확인
print(data)
# 선형 회귀 모델 학습
model <- lm(count ~ year, data = data)
# 회귀분석 결과 출력
summary(model)
```

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 127p

2 데이터 분석 도구에는 무엇이 있을까?

예제 2

코딩 도구인 파이썬과 R 프로그래밍을 통해 동일한 데이터를 시각화해 보자.

R

```
# 시각화
ggplot(data, aes(x = year, y = count)) +
  geom_point() +
  geom_smooth(method = 'lm', se = FALSE) +
  labs(title = 'example', x = 'year', y = 'count') +
  theme_minimal()
```


1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 127p

2 데이터 분석 도구에는 무엇이 있을까?


예제 2

[결과 화면 확인하기]

파이썬



R




1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 128p

2 데이터 분석 도구에는 무엇이 있을까?

더 알아보기

데이터 분석에 필요한 지표

회귀분석(평균 제곱 오차)



- 독립 변수와 종속 변수 간의 인과관계를 찾기 위한 방법
- 대표적인 지표인 평균 제곱 오차(MSE: Mean Squared Error)를 사용
- 오차의 제곱합을 평균 내어 평가할 수 있으며 값이 작을수록 회귀 분석의 예측이 더 정확하다는 것을 의미

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 128p

2 데이터 분석 도구에는 무엇이 있을까?

더 알아보기

데이터 분석에 필요한 지표

분류 분석(정확도)



- 분류 분석은 미리 정해놓은 그룹 중 어느 그룹에 데이터가 속하는지 예측하는 방법
- 대표적인 지표인 정확도(accuracy)는 모델이 정확하게 예측한 데이터의 비율을 나타냄
- 정확도가 1에 가까울수록 분류 분석의 예측이 더 정확하다는 것을 의미

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 128p

2 데이터 분석 도구에는 무엇이 있을까?

더 알아보기

데이터 분석에 필요한 지표

군집 분석(실루엣 계수)



- 군집 분석은 유사한 성향을 가진 데이터들을 그룹화하는 방법
- 사전에 정해진 분류 기준이나 레이블이 없기 때문에 군집된 데이터 간의 거리를 기반으로 평가
- 실루엣 계수(silhouette coefficient) 값이 1에 가까울수록 군집이 잘 형성되었음을 의미

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 128p

2 데이터 분석 도구에는 무엇이 있을까?

더 알아보기

데이터 분석에 필요한 지표

연관 분석(지도, 신뢰도, 항상도)



- 연관분석은 데이터에서 항목 간의 규칙이나 관계를 찾아내는 방법
- 발견된 규칙의 유용성을 판단하고 항목 간의 연관성을 측정
- **지도도(support)**: 데이터 집합에서 규칙이 얼마나 자주 발생하는지를 나타낸다.
- **신뢰도(confidence)**: 규칙이 성립했을 때 그 규칙이 맞을 확률을 나타낸다.
- **항상도(ift)**: 규칙이 얼마나 유용한지를 나타내는 지표로, 신뢰도를 해당 규칙의 뒷부분이 발생한 확률로 나눈 값이다.

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 129p

2 데이터 분석 도구에는 무엇이 있을까?

함께 해결하기

분석 발표

코딩 도구와 노코딩 도구의 차이점을 분석해 보고, 친구들과 함께 공유해 보자.

1. 원하는 데이터를 선택하고 이를 활용한 오렌지 프로그램과 파이썬 프로그램을 각각 실행해 보자.

노코딩 도구(오렌지 프로그램)

① 'dataset' 위젯으로 붓꽃(iris) 데이터를 불러와 'datatable' 위젯으로 확인한다.



1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 129p

2 데이터 분석 도구에는 무엇이 있을까?

함께 해결하기

분석 발표

코딩 도구와 노코딩 도구의 차이점을 분석해 보고, 친구들과 함께 공유해 보자.

1. 원하는 데이터를 선택하고 이를 활용한 오렌지 프로그램과 파이썬 프로그램을 각각 실행해 보자.

노코딩 도구(오렌지 프로그램)

② 'Select Columns' 위젯을 연결하여, Linear Regression 모델링에 필요한 feature와 target 속성을 선택한다. (feature는 petal_width, target은 sepal_length로 한다.)



1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 129p

2 데이터 분석 도구에는 무엇이 있을까?

함께 해결하기


분석 발표

코딩 도구와 노코딩 도구의 차이점을 분석해 보고, 친구들과 함께 공유해 보자.

1. 원하는 데이터를 선택하고 이를 활용한 오렌지 프로그램과 파이썬 프로그램을 각각 실행해 보자.

노코딩 도구(오렌지 프로그램)

③ Data Sampler 위젯에서 훈련 데이터와 테스트 데이터의 비율을 설정하고, Linear Regression 위젯으로 학습을 시키고, Test and Score 위젯으로 성능을 확인한다.



1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 129p

2 데이터 분석 도구에는 무엇이 있을까?

함께 해결하기

분석 발표

코딩 도구와 노코딩 도구의 차이점을 분석해 보고, 친구들과 함께 공유해 보자.

1. 원하는 데이터를 선택하고 이를 활용한 오렌지 프로그램과 파이썬 프로그램을 각각 실행해 보자.

코딩 도구(파이썬)

① 붓꽃 데이터를 불러와 데이터를 확인한다.

```

1 from sklearn.datasets import load_iris
2 from sklearn.linear_model import LinearRegression
3 from sklearn.model_selection import train_test_split
4 from sklearn.metrics import mean_absolute_error,
5   mean_squared_error, r2_score
6 import numpy as np
7
8 iris = load_iris() # 데이터 로드
9 X = iris.data[:, 3:] # petal_width
10 y = iris.target # sepal_length

```

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 129p

2 데이터 분석 도구에는 무엇이 있을까?

함께 해결하기

분석 발표

코딩 도구와 노코딩 도구의 차이점을 분석해 보고, 친구들과 함께 공유해 보자.

1. 원하는 데이터를 선택하고 이를 활용한 오렌지 프로그램과 파이썬 프로그램을 각각 실행해 보자.

코딩 도구(파이썬)

② 훈련 데이터와 테스트 데이터를 7:3으로 분할한다.

```

1 # 훈련/테스트 데이터 분할 (7:3 비율)
2 X_train, X_test, y_train, y_test = train_test_split(X,
3   y, test_size = 0.3, random_state = 42)

```

③ 선형 회귀 모델을 학습한다.

```

1 # 선형 회귀 모델 학습
2 model = LinearRegression()
3 model.fit(X_train, y_train)

```

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 129p

2 데이터 분석 도구에는 무엇이 있을까?

함께 해결하기

코딩 도구와 노코딩 도구의 차이점을 분석해 보고, 친구들과 함께 공유해 보자.

1. 원하는 데이터를 선택하고 이를 활용한 오렌지 프로그램과 파이썬 프로그램을 각각 실행해 보자.

코딩 도구(파이썬)

④ 모델 성능 지표를 확인한다.

```

> 1 y_pred = model.predict(X_test) # 예측값 구하기
2
3 # 성능 지표 계산
4 r2 = r2_score(y_test, y_pred)
5 mae = mean_absolute_error(y_test, y_pred)
6 mse = mean_squared_error(y_test, y_pred)
7 rmse = np.sqrt(mse)
8
  
```

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 129p

2 데이터 분석 도구에는 무엇이 있을까?

함께 해결하기

코딩 도구와 노코딩 도구의 차이점을 분석해 보고, 친구들과 함께 공유해 보자.

1. 원하는 데이터를 선택하고 이를 활용한 오렌지 프로그램과 파이썬 프로그램을 각각 실행해 보자.

코딩 도구(파이썬)

④ 모델 성능 지표를 확인한다.

```

> 9 # 출력
10 print('R² score: {r2:.4f}'.format(r2=r2)) # 결정 계수
11 print('MAE: {mae:.4f}'.format(mae=mae)) # 평균 절대값 오차
12 print('MSE: {mse:.4f}'.format(mse=mse)) # 평균 제곱 오차
13 print('RMSE: {rmse:.4f}'.format(rmse=rmse)) # 평균 제곱근 오차

R² score: 0.7383
MAE: 0.3118
MSE: 0.1742
RMSE: 0.4174
  
```

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 129p

2 데이터 분석 도구에는 무엇이 있을까?

함께 해결하기

코딩 도구와 노코딩 도구의 차이점을 분석해 보고, 친구들과 함께 공유해 보자.

2. 두 도구를 사용하면서 느낀 차이점을 정리하고, 친구들과 함께 공유해 보자.

오렌지는 위젯을 연결해 직관적으로 선형 회귀 과정을 이해하고 결과를 쉽게 볼 수 있어 편리했고, 파이썬은 코드 입력이 어려웠지만 세부 과정을 자유롭게 조절할 수 있는 장점이 있었다.

1. 데이터 모델과 회귀분석 > 1-1. 데이터 모델 | 129p

1-1 데이터 모델

주요 개념을 점검하기!

- ① 데이터 모델은 데이터를 이해하고 정보를 추출하는 과정에서 사용되는 다양한 방법이나 기술을 말하며, 데이터의 특성을 파악하여 예측, 군집, 연관분석 등의 작업을 수행하는 데 활용된다.
- ② 데이터 분석에 다양한 분석 도구나 프로그래밍 언어를 적절히 선택하고 활용한다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 130p

1-2 회귀분석

학습 목표

- 통계적 회귀 모델과 기계학습을 통한 회귀 모델을 비교할 수 있다.
- 데이터를 분석하여 결과를 해석할 수 있다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 130p

1-2 회귀분석

현대 사회에서 수많은 데이터를 기반으로 미래를 예측하거나 추세를 파악하는 것은 매우 중요하다. 우리는 다양한 데이터에서 연속적인 결과를 예측하기 위해 여러 분석 방법을 활용한다. 예를 들어, 학생들이 공부한 시간 및 기타 요인들에 따라 시험 성적을 예측하거나, 특정 제품의 판매량을 과거 데이터를 통해 예측할 수 있다. 이러한 예측의 핵심 도구 중 하나가 바로 회귀분석이다. 회귀분석은 두 변수 간의 관계를 수학적으로 표현하여, 주어진 변수로부터 결과를 예측할 수 있게 한다.

회귀분석에서 통계적 회귀 모델과 기계 학습을 통한 회귀 모델의 차이점은 무엇이며, 어떻게 구별할 수 있을까?

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 130p

데이터 과학으로 문제를 바라본다면?

영화 제작사는 항상 큰 고민에 빠진다. '이 영화가 과연 흥행할까?' 만약 흥행에 실패하면 큰 손해를 볼 수 있기 때문에 제작사들은 이 질문에 답하기 위해 데이터를 분석하기 시작했다.



1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 130p

데이터 과학으로 문제를 바라본다면?

영화 산업에서 회귀분석은 중요한 도구로 사용된다. 예를 들어, 과거 영화 데이터를 바탕으로 주연 배우의 인기, 감독의 인지도, 영화 예산, 개봉일, 홍보 비용, 그리고 영화의 장르같은 요소들이 흥행에 어떤 영향을 미치는지 분석할 수 있다. 이런 데이터를 바탕으로 제작사는 앞으로 영화 제작과 개봉 전략을 더욱 효율적으로 계획할 수 있게 되었다. 다시 말해, 회귀분석 덕분에 영화 제작사는 수익성을 극대화하는 전략을 세우는 데 도움을 받을 수 있게 된 것이다.



1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 131p

1 회귀 분석이란 무엇일까?

1 회귀 분석의 개념

회귀분석(regression analysis)

여러 변수 사이의 관계를 쉽게 이해하고, 이를 통해 결과를 예측하는 방법

학생의 시험 점수 예측

결과에 영향을 주는 원인(독립 변수)			예측하고 싶은 결과(종속 변수)
공부 시간(x_1)	수면 시간(x_2)	게임 시간(x_3)	시험 점수(y)
10	7	2	90.5
5	8	5	75.5

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 131p

1 회귀 분석이란 무엇일까?

2 회귀분석에 사용하는 모델의 종류

회귀분석 모델 구분

1차 함수선형 회귀 모델

독립 변수와 종속 변수간의 관계가 직선 형태로 나타날 때, 변수 간의 직선적인 관계를 모델링

2차 함수비선형 회귀 모델

독립 변수와 종속 변수 간의 관계가 곡선 형태로 나타날 때 사용되며, 더 복잡한 패턴을 설명하는 데 적합

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 131p

1 회귀 분석이란 무엇일까?

선형 회귀 모델

하나 이상의 독립 변수와 종속 변수 사이의 선형 관계를 모델링하는 회귀분석의 기본 형태

목적

독립 변수들이 종속 변수에 미치는 영향을 계수(ω)로 추정하여, 주어진 데이터에 가장 적합한 직선 방정식을 구하고 이를 통해 예측

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 131p

1 회귀 분석이란 무엇일까?

선형 회귀 모델

하나 이상의 독립 변수와 종속 변수 사이의 선형 관계를 모델링하는 회귀분석의 기본 형태

종류

독립 변수의 개수

1개: 단순 선형 회귀 모델

$$y = \omega x + b$$

2개 이상: 다중 선형 회귀 모델

$$y = \omega_1 x_1 + \omega_2 x_2 + \omega_3 x_3 + b$$

- y 는 종속 변수(예측값)
 - x_1, x_2, x_3 는 독립 변수(영향을 주는 변수들)
 - $\omega_1, \omega_2, \omega_3$ 는 각 독립 변수가 종속 변수에 미치는 영향력을 나타내는 계수 b 는 절편

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 131p

1 회귀 분석이란 무엇일까?

비선형 회귀 모델

독립 변수와 종속 변수 간의 복잡한 관계를 곡선 또는 다양한 수학적 함수로 표현하는 모델

목적

독립 변수와 종속 변수 간의 관계를 선형이 아닌 비선형 함수로 모델링하여, 선형 회귀로 설명할 수 없는 복잡한 패턴을 해석하고 예측

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 131p

1 회귀 분석이란 무엇일까?

비선형 회귀 모델

독립 변수와 종속 변수 간의 복잡한 관계를 곡선 또는 다양한 수학적 함수로 표현하는 모델

종류

- 앙상블(ensemble) 모델: 여러 개의 예측 모델을 결합하여 사용한다. 예를 들어 랜덤 포레스트는 다수의 의사결정트리를 조합하여 강력한 예측 성능을 발휘한다.
- 신경망(neural networks): 인간의 뇌 신경 구조를 모방한 알고리즘으로, 복잡하고 비선형적인 데이터 패턴을 학습할 수 있다.
- 그 외: 2차 다항 회귀($y = \omega_1 x^2 + \omega_2 x + b$), 지수 회귀($y = \omega_1 e^{\omega_2 x} + b$), 로그 회귀($y = \omega_1 \ln(\omega_2 x + b)$)

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 132p

1 통계적 회귀와 기계학습 회귀의 차이는 무엇일까?

1 통계학

통계학

데이터를 수집하고 분석하여 규칙성과 불규칙성을 나타내고, 이를 바탕으로 예측 및 의사 결정을 지원하는 학문

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 132p

1 통계적 회귀와 기계학습 회귀의 차이는 무엇일까?

1 통계학

- 역사적으로 통계학은 인구 조사에서 시작되어 보험, 의학, 경제, 사회학 등 다양한 분야에서 폭넓게 활용됨

고대 로마 시대의 인구 조사



고대 로마제국의 초대 황제 아우구스투스(기원전 63~기원후 14년)는 군사력을 정확하게 파악하기 위해 17세 이상의 남자를 조사하여 징병과 징세를 시행했다.
이는 인구 데이터를 바탕으로 국가 정책을 결정한 초기 통계적 접근이다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 132p

1 통계적 회귀와 기계학습 회귀의 차이는 무엇일까?

1 통계학

- 역사적으로 통계학은 인구 조사에서 시작되어 보험, 의학, 경제, 사회학 등 다양한 분야에서 폭넓게 활용됨

보험의 기초가 된 헬리의 생명표

헬리가 정제한 브뤼셀과루우 시의 연도별 출생과 사망자 수(1687~1693)

연도	출생자 수	사망자 수
1687	1,186	940
1688	1,214	956
1689	1,191	954
1690	1,282	989
1691	1,252	988
1692	1,151	857

천문학자 애드먼드 헬리(1652~1742년)는 사람들의 출생과 사망 데이터를 평균 기대 수명을 정리한 '생명표'를 만들었다.
이는 보험과 같은 오늘날의 위험 관리와도 관련이 있는 통계학의 중요한 활용 사례이다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 132p

2 통계적 회귀와 기계학습 회귀의 차이는 무엇일까?

1 통계학

- 역사적으로 통계학은 인구 조사에서 시작되어 보험, 의학, 경제, 사회학 등 다양한 분야에서 폭넓게 활용됨

존 스노우의 콜레라 발병 지도



의학자 존 스노우(1813~1858년)는 사망자의 주소를 표시한 '콜레라 지도'를 통해 공용 펌프를 중심으로 콜레라가 퍼졌다는 사실을 밝혀냈다.
이는 질병의 확산 경로를 시각적으로 파악한 초기 사례로, 통계적 분석이 얼마나 중요한 역할을 할 수 있는지를 보여 준다.


1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 132p

2 통계적 회귀와 기계학습 회귀의 차이는 무엇일까?

2 기계학습

- 역사적으로 통계학은 인구 조사에서 시작되어 보험, 의학, 경제, 사회학 등 다양한 분야에서 폭넓게 활용됨

실시간 데이터 분석과 도시 계획



기계학습으로 인구 데이터, 이동 패턴, 소셜 미디어 텍스트, CCTV 영상 등 다양한 데이터를 실시간으로 수집하고 분석하여 **도시 계획과 공공 정책 결정을 지원**한다.

기계학습 모델은 **교통 혼잡 지역을 파악**하는 데 매우 유용하며, **교통 문제를 해결할 방안을 평가**하고 **계획**하는 데 도움을 준다.


1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 132p

2 통계적 회귀와 기계학습 회귀의 차이는 무엇일까?

2 기계학습

- 역사적으로 통계학은 인구 조사에서 시작되어 보험, 의학, 경제, 사회학 등 다양한 분야에서 폭넓게 활용됨

맞춤형 보험 서비스와 위험도 관리



보험 회사들은 고객의 건강, 재정 데이터와 웨어러블 기기에서 수집된 센서 데이터 등 방대한 데이터를 분석하여 개인화된 상품을 제공한다. 기계학습 모델은 텍스트와 이미지 데이터를 함께 활용하여 **고객의 위험도를 정밀하게 평가**하고, **보험료를 계산**하여 **비율을 자동으로 조정**하는 데 기여한다.


1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 132p

2 통계적 회귀와 기계학습 회귀의 차이는 무엇일까?

2 기계학습

- 역사적으로 통계학은 인구 조사에서 시작되어 보험, 의학, 경제, 사회학 등 다양한 분야에서 폭넓게 활용됨

기계학습을 이용한 질병 예측



의료 분야에서는 기계학습이 질병 예측에 활용되며, 의료 영상, 유전자 정보, 환자의 실시간 모니터링 데이터 등을 **분석하여 질병의 위험 요인을 파악**한다.

특히 **당뇨병 예측**을 위한 기계학습 모델은 **질병의 조기 발견과 예방**에 중요한 역할을 하고 있다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 133p

2 통계적 회귀와 기계학습 회귀의 차이는 무엇일까?

3 통계적 회귀 모델과 기계학습 회귀 모델의 차이

- 통계학과 기계학습은 각각의 특징과 장단점을 가지고 있으며, 그 사용 목적과 환경에 따라 선택적으로 활용될 수 있음.

통계적 회귀 모델은 가설을 세우고, 데이터가 통계적 가정을 충족하는지 확인한 뒤, 가설검정 단계를 거쳐 신뢰할 수 있는 결론을 도출할 수 있어 이 과정에서 변수 간의 관계가 우연이 아닌 통계적으로 유의미한지 결정하지.

통계적 회귀 모델은 직관적이며, 결과를 해석하기도 쉽고, 변수들 간의 관계를 명확하게 보여 줄 수 있어, 그래서 데이터를 분석한 뒤 바로 이해하고 설명할 수 있지.

기계학습 회귀 모델은 가설을 세우거나 통계적으로 유의미한지 검증하는 것보다, 데이터 학습한 데이터를 기반으로 얼마나 정확하게 예측할 수 있는지를 중요시해.

하지만, 요즘처럼 데이터가 폭발하고 대규모일 때는 기계학습 회귀 모델이 훨씬 강력해. 텍스트, 이미지, 그리고 영상과 같이 다양한 데이터도 처리할 수 있지.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 133p

2 통계적 회귀와 기계학습 회귀의 차이는 무엇일까?

3 통계적 회귀 모델과 기계학습 회귀 모델의 차이

- 통계학과 기계학습은 각각의 특징과 장단점을 가지고 있으며, 그 사용 목적과 환경에 따라 선택적으로 활용될 수 있음.

그것도 기계학습 회귀 모델은 해석이 어렵다는 문제가 있지. 예를 들어, 머신러닝 학습이 끝나는 결과보다 훨씬 더 중요한 결과가 많잖아. 요일의 확률을 직관적으로 해석할 수 있고, 어떤 변수가 중요한지 바로 알 수 있어야 근본적으로 해결되지.

결과 목적과 데이터에 맞게 활용하는 게 중요하지 않을까?

해석 가능성은 중요한 요소이긴 해. 하지만 금융 사기 탐지나 자율주행 자동차와 같이 결과가 더 중요한 상황도 많잖아. 이때는 해 그런 결정을 내린다는 이유보다 빠른 결정이 더 중요하지.

그런 상황에 맞게 각각의 강점을 살려 회귀의 결과를 만들어 보자!

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 133p

2 통계적 회귀와 기계학습 회귀의 차이는 무엇일까?

3 통계적 회귀 모델과 기계학습 회귀 모델의 차이

- 통계학과 기계학습은 각각의 특징과 장단점을 가지고 있으며, 그 사용 목적과 환경에 따라 선택적으로 활용될 수 있음.

표 3-3 통계적 회귀 모델과 기계학습 회귀 모델

모델	통계적 회귀 모델	기계학습 회귀 모델
목표	변수 간의 관계 해석과 통계적 유의미성 검증에 중점을 둬	예측의 정확도를 최대화하는 것에 중점을 둬.
데이터의 다양성	소량의 데이터에 초점을 맞춤.	대용량 데이터도 효과적으로 처리함.
가설 및 전제 조건	가설을 세우고 통계적 가정을 만족해야 함.	가설을 세우거나 가정을 하지 않고, 가설과 가정에 덜 민감함.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 133p

2 통계적 회귀와 기계학습 회귀의 차이는 무엇일까?

3 통계적 회귀 모델과 기계학습 회귀 모델의 차이

- 통계학과 기계학습은 각각의 특징과 장단점을 가지고 있으며, 그 사용 목적과 환경에 따라 선택적으로 활용될 수 있음.


표 III-3 통계적 회귀 모델과 기계학습 회귀 모델

모델	통계적 회귀 모델	기계학습 회귀 모델
모델의 차이	주로 선형 회귀와 같이 해석이 용이하고, 변수 간의 관계를 명확히 이해할 수 있는 모델 사용	주로 인공신경망, 랜덤 포레스트 등 복잡한 비선형 모델을 사용하여 복잡한 패턴을 학습할 수 있는 모델
결과의 해석	해석이 가능하여 결과에 대한 원인을 설명하거나 해석하기 쉬움(white box model).	예측 성능이 높지만, 결과에 대한 원인을 설명하거나 해석하기 어려운 경우가 많음(black box model).
예시	- 가설: 공부 시간이 많을수록 성적이 올라갈 것이다. - 결과: 공부 시간의 증가가 성적에 얼마나 영향을 미치는지 명확히 설명할 수 있다.	성적을 가장 정확하게 예측할 수 있는 모델을 만든다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 133p

2 통계적 회귀와 기계학습 회귀의 차이는 무엇일까?

3 통계적 회귀 모델과 기계학습 회귀 모델의 차이



💡 사용 목적과 데이터의 특성에 따라 적절한 회귀모델을 선택하는 것이 중요함

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 134p

3 통계적 회귀 모델을 이용하여 분석해 볼까?


통계적 회귀분석

- 데이터를 이용해 변수 간의 관계를 분석하고, 그 관계가 실제로 의미 있는지를 평가하는 방법
- 통계적 회귀분석을 통해 어떤 변수가 다른 변수에 영향을 미치는지를 확인하고 해석할 수 있음

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 134p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

캘리포니아 주택 가격 데이터셋을 활용한 통계적 회귀 분석



1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 134p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

1 가설 설정

가설 설정

귀무가설과 대립가설을 세워 우리가 예상하는 결과가 맞는지 맞지 않는지를 실험으로 검증하는 과정

귀무가설

'아무런 변화도 없다'라는 것을 주장하는 기본적인 가정

대립가설

'무엇인가 영향이 있다'라는 것을 주장하여 영향을 미치는 요인을 확인하고자 하는 가정

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 134p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

1 가설 설정

표 III-4 귀무가설과 대립가설의 예시

구분	귀무가설	대립가설
집값	집값은 소득이나 방의 개수와 같은 독립 변수에 영향을 받지 않는다. 즉, 통계적 검정을 통해 귀무가설이 기각되면, 소득이나 방의 개수가 집값에 영향을 미친다고 결론을 내릴 수 있다.	집값은 적어도 하나 이상의 독립 변수에 영향을 받는다. 즉, 귀무가설을 기각했을 때 채택되며, 분석을 통해 독립 변수가 집값에 영향을 미친다고 판단하게 되어 소득이 높아지면 집값도 오를 수 있다는 결론을 내릴 수 있다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 134p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

2 데이터 수집 및 전처리

(1)데이터 수집

- 필요한 라이브러리를 불러오고, '파일 선택' 버튼을 눌러받은 캘리포니아 주택 가격 데이터셋(housing.csv) 파일을 선택하여 업로드함
- 업로드된 파일을 읽어와 data 데이터프레임을 생성

```

> 1 import pandas as pd # 데이터를 로드하고 처리하는데 사용
2 import statsmodels.api as sm # 통계적 회귀 모델을 생성하고 분석하는데 사용
3 from sklearn.model_selection import train_test_split # 훈련용과 테스트용 데이터셋 구분
4 from google.colab import files # 사용자 파일 업로드 기능 제공
5
6 file_path = list(files.upload().keys())[0] # 사용자가 파일을 업로드할 수 있도록 함.
7 data = pd.read_csv(file_path) # 업로드할 파일 읽어옴.

```

*** 파일 선택 선택된 파일 없음 Cancel upload

실습데이터

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 135p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

2 데이터 수집 및 전처리

- info() 함수를 사용해 데이터의 구조와 정보를 확인함

```

> 1 data.info() # 데이터셋의 속성명, 속성별 데이터 개수, 자료형 확인

```

#	Column	Non-Null	Count	Dtype
0	crim	non-null	506	float64
1	lstat	non-null	506	float64
2	medv	non-null	506	float64
3	total_rooms	non-null	506	float64
4	total_bedrooms	non-null	506	float64
5	population	non-null	506	float64
6	household	non-null	506	float64
7	median_income	non-null	506	float64
8	ocean_proximity	non-null	506	object

total_bedrooms 속성의 데이터 수가 20,433으로 다른 속성보다 더 적은 것으로 보아 결측치가 있는 것으로 확인된다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 135p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

2 데이터 수집 및 전처리

(2)데이터 전처리

- 데이터 전처리는 결측치나 이상치와 같은 분석에 방해가 되는 요소들을 처리하는과정
- 회귀분석에 사용되지 않는 변수 삭제, 결측치 처리, 독립 변수와 종속 변수 설정함

```

> 1 # 범주형 변수 제외
2 data_clean = data.drop(columns = ['ocean_proximity']) # ocean_proximity 속성은 범주형 변수로,
3 # 결측치 처리 회귀분석에서 사용되지 않으므로 제거한다.
4 data_clean = data_clean.fillna(data_clean.median())
5

```

결측치는 해당 열의 중앙값으로 대체한다.
중앙값은 데이터에 극단적인 값(이상치)이 포함되어 있어도 그 영향을 크게 받지 않기 때문이다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 135p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

2 데이터 수집 및 전처리

(2)데이터 전처리

- 데이터 전처리는 결측치나 이상치와 같은 분석에 방해가 되는 요소들을 처리하는과정
- 회귀분석에 사용되지 않는 변수 삭제, 결측치 처리, 독립 변수와 종속 변수 설정함

```

> 6 # 독립 변수(X)와 종속 변수(y) 설정
7 X = data_clean.drop(columns = ['median_house_value']) # 독립 변수(X)는 주택 가격에 영향을 미칠 수 있는
8 y = data_clean['median_house_value'] # 변수를, 종속 변수(y)는 예측하고자 하는 주택 가격
9 # (median_house_value)을 설정한다.
10
11 # 데이터셋을 훈련용과 테스트용으로 분할
12 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2,
random_state = 42)

```

train_test_split을 사용하여 데이터를 훈련용(80%)과 테스트용(20%)으로 나눈다.
random_state는 코드를 여러 번 실행해도 동일한 결과를 얻기 위해 사용한다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 136p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

3 모델 생성 및 학습

- 훈련 데이터(X_train)와 테스트 데이터(X_test)에 상수항을 추가한 후, 최소제곱법(OLS)을 사용하여 회귀 모델을 생성하여 학습시킨다.

```

> 1 # 상수항 추가 (statsmodels를 사용하기 위해 필요)
2 X_train_const = sm.add_constant(X_train)
3 X_test_const = sm.add_constant(X_test) # sm.add_constant()는 statsmodels 라이브
4 # 선행 회귀 모델 생성 및 학습 러리의 함수로, 입력 데이터(X)에 상수항을 주
5 # lin_reg = sm.OLS(y_train, X_train_const).fit() 가한다.
6

```

sm.OLS는 최소제곱법(Ordinary Least Squares) 기반의 선행 회귀 모델을 생성하는 함수이다.
fit()를 이용해 모델을 학습시키고 학습 결과는 lin_reg에 저장되며, 회귀계수, 결정 계수, 오차 등
의 다양한 분석 결과를 확인할 수 있다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 136p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

4 가설검정

- 회귀 모델이 생성한 결과를 바탕으로 가설을 검정
- 유의수준(p-값)을 통해 독립 변수가 종속 변수에 유의미한 영향을 미치는지 확인할 수 있음

```

> 1 print('선행 회귀 모델 (가설검정 포함):')
2 print(lin_reg.summary())

```

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 136p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

4 가설검정

OLS 회귀분석 결과 요약 해석

선행 회귀 모델 (가설검정 포함):

```

OLS Regression Results
=====
Dep. Variable: median_house_value
Model: OLS
Date: Sat, 05 Oct 2024
Time: 07:33:14
No. Observations: 16512
DF Residuals: 16503
DF Model: 8
Coverage Type: nonrobust
R-squared: 0.640
Adj. R-squared: 0.639
Prob (F-statistic): 0.00
F-statistic: -2.8740e+05
AIC: 4.150e+05
BIC: 4.151e+05
=====

```

① Dep. Variable(종속 변수): 회귀분석에서 예측하려는 변수의 이름이다.
 ② Model: 최소제곱법(OLS Ordinary Least Squares)을 사용한 선형 회귀 모델이다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 136p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

4 가설검정

OLS 회귀분석 결과 요약 해석

선행 회귀 모델 (가설검정 포함):

```

OLS Regression Results
=====
Dep. Variable: median_house_value
Model: OLS
Date: Sat, 05 Oct 2024
Time: 07:33:14
No. Observations: 16512
DF Residuals: 16503
DF Model: 8
Coverage Type: nonrobust
R-squared: 0.640
Adj. R-squared: 0.639
Prob (F-statistic): 0.00
F-statistic: -2.8740e+05
AIC: 4.150e+05
BIC: 4.151e+05
=====

```

③ R-squared(결정 계수): 모델이 데이터를 얼마나 잘 설명하는지를 나타낸다. 0에서 1 사이의 값을 가지며, 0.64라는 것은 모델이 종속 변수의 변동성 중 약 64%를 설명한다는 의미이다.
 ④ Adj. R-squared(수정된 결정 계수): 결정 계수와 유사하지만, 독립 변수의 개수를 고려하여 조정된 값이다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 136p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

4 가설검정

OLS 회귀분석 결과 요약 해석

선행 회귀 모델 (가설검정 포함):

```

OLS Regression Results
=====
Dep. Variable: median_house_value
Model: OLS
Date: Sat, 05 Oct 2024
Time: 07:33:14
No. Observations: 16512
DF Residuals: 16503
DF Model: 8
Coverage Type: nonrobust
R-squared: 0.640
Adj. R-squared: 0.639
Prob (F-statistic): 0.00
F-statistic: -2.8740e+05
AIC: 4.150e+05
BIC: 4.151e+05
=====

```

⑤ Prob(F-statistic): F-statistic에 대한 p-값으로, 0.00이라는 것은 유의 수준(0.05)보다 작으므로, 모델 전체가 통계적으로 의미 있다고 판단할 수 있다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 136p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

4 가설검정

OLS 회귀분석 결과 요약 해석

⑥ 회귀계수(Coefficients) 전체 결과 미리 보기

	coef	std err	t	P> t	[0.025	0.975]
const	-3.578e+06	6.96e+04	-51.430	0.000	-3.71e+06	-3.44e+06
longitude	-4.263e+04	793.241	-53.745	0.000	-4.42e+04	-4.11e+04
latitude	-4.245e+04	749.579	-56.632	0.000	-4.39e+04	-4.1e+04
housing_median_age	1182.8896	48.048	24.617	0.000	1088.630	1276.989
total_rooms	-5.1888	0.889	-5.289	0.000	-6.911	-3.445
total_bedrooms	116.2681	7.765	14.973	0.000	101.840	131.480
population	-38.4922	1.196	-32.179	0.000	-40.817	-36.148
households	46.3426	8.483	5.463	0.000	29.715	62.970
median_income	4.054e+04	374.128	108.354	0.000	3.98e+04	4.13e+04

Omnibus: 4022.722 Durbin-Watson: 1.964
 Prob(Omnibus): 0.000 Jarque-Bera (JB): 16069.859
 Skew: 1.161 Prob(JB): 0.00
 Kurtosis: 7.238 Cond. No.: 5.09e+05

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 136p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

4 가설검정

OLS 회귀분석 결과 요약 해석

⑥ 회귀계수(Coefficients)

- const(상수항): 모든 독립 변수가 0일 때 주택 가격의 기본값을 의미한다.
- longitude(경도): 경도가 1도 증가할 때 주택 가격이 약 42,630달러 감소한다.
- latitude(위도): 위도가 1도 증가할 때 주택 가격이 약 42,450달러 감소한다.
- housing_median_age(주택 나이(중앙값)): 주택 연령이 1년 증가할 때 주택 가격이 약 1,183달러 증가한다.
- total_rooms(전체 방 개수): 방의 개수가 1개 증가할 때 주택 가격이 약 819달러 감소한다.
- total_bedrooms(전체 침실 개수): 침실 개수가 1개 증가할 때 주택 가격이 약 116,268달러 증가한다.
- population(인구수): 인구가 1명 증가할 때 주택 가격이 약 38.49달러 감소한다.
- households(가구 수): 가구 수가 1개 증가할 때, 주택 가격이 약 46,342달러 증가한다.
- median_income(중간 소득): 중간 소득이 1 단위(약 만 달러) 증가할 때, 주택 가격이 약 40,540달러 증가한다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 137p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

5 평가

- OLS 회귀분석 결과, 결정 계수(R²) 값이 0.64로 나타나 이 모델은 전체적으로 약 64%의 설명력을 가짐. 이는 독립 변수들이 주택 가격 변동성의 약 64%를 설명할 수 있음을 의미함
- 모델의 설명력이 0.64로 매우 높지는 않지만, 주택 가격을 예측하는 데 있어 유의미한 정보를 제공한다고 볼 수 있음.
- F-통계의 유의 수준(Prob F-statistic)이 0.00으로 매우 낮게 나타나, 회귀 모델이 통계적으로 유의미함을 나타냄.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 137p

3 통계적 회귀 모델을 이용하여 분석해 볼까?

5 평가

- 각 독립 변수의 유의 수준이 0.05보다 작기 때문에, 모든 독립 변수가 주택 가격에 통계적으로 유의미한 영향을 미친다고 해석할 수 있음.
- 중간 소득(median_income)의 회귀계수(coef) 값이 가장 크고 유의 수준이 매우 낮아, 중간 소득이 주택 가격에 가장 큰 영향을 미치는 변수로 판단됨.
- 결론적으로, 회귀분석 결과는 독립 변수들이 캘리포니아 주택 가격에 유의미한 영향을 미친다는 것을 보여 주며, 특히 중간 소득 변수가 가장 중요한 요인으로 확인됨.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 137p

4 기계학습 회귀 모델을 이용하여 분석해 볼까?

기계학습 회귀 분석

- 데이터에서 패턴을 학습하여 독립 변수들로부터 연속적인 종속 변수를 예측하는 방법
- 미래의 값을 예측하거나 변수 간의 관계를 분석할 수 있음

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 138p

4 기계학습 회귀 모델을 이용하여 분석해 볼까?

캘리포니아 주택 가격 데이터셋을 활용한 기계 학습 회귀 분석

가설 설정 → 데이터 수집 및 전처리 → 모델 생성 및 학습 → 가설검정 → 평가

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 138p

4 기계학습 회귀 모델을 이용하여 분석해 볼까?

1 데이터 수집 및 전처리

- 데이터 값의 범위 차이가 모델의 성능에 영향을 미칠 수 있기 때문에 Min-Max 스케일링을 사용하여 변수(feature) 간 크기 차이를 0~1 사이의 값으로 조정

```

> 1 scaler = MinMaxScaler() # Min-Max 스케일링 적용
2   X_scaled = scaler.fit_transform(X)
3   # 데이터셋을 훈련용과 테스트용으로 분할
4   X_train, X_test, y_train, y_test = train_test_split(X_scaled, y, test_size = 0.2,
5                                                       random_state = 42)

```

- Min-Max 스케일링은 각 변수(feature)의 최솟값과 최댓값을 기준으로 데이터를 0과 1 사이의 범위로 변환함
- Min-Max 스케일링을 통해 모델이 각 변수의 상대적 크기에 덜 민감해지도록 하여 학습 과정에서 성능을 높일 수 있음

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 138p

4 기계학습 회귀 모델을 이용하여 분석해 볼까?

2 모델 생성 및 학습

- 선형 회귀, 랜덤 포레스트, 인공신경망을 사용해 각각의 모델을 학습시키고 예측을 수행함

```

> 1 # 선형 회귀 모델
2 lin_model = LinearRegression()
3 lin_model.fit(X_train, y_train)
4 y_pred_lin = lin_model.predict(X_test)
5 # 랜덤 포레스트 회귀 모델
6 rf_model = RandomForestRegressor(n_estimators = 100, random_state = 42)
7 rf_model.fit(X_train, y_train)
8 y_pred_rf = rf_model.predict(X_test)
9 # 인공신경망 회귀 모델
10 nn_model = MLPRegressor(hidden_layer_sizes = (100, 50), max_iter = 500,
11                          random_state = 42)
12 nn_model.fit(X_train, y_train)
13 y_pred_nn = nn_model.predict(X_test)

```

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 139p

4 기계학습 회귀 모델을 이용하여 분석해 볼까?

2 모델 생성 및 학습

• 선형 회귀

독립 변수(X_train)와 종속 변수(y_train) 간의 선형 관계를 찾아내는 가장 기본적인 회귀 모델, 직선을 사용해 데이터를 예측함

• 랜덤 포레스트(random forest)

앙상블 학습 기법 중 하나로, 여러 개의 결정 트리를 학습시켜 그 결과를 결합하여 예측을 수행하며, 이를 통해 모델의 안정성과 정확성을 높임

• 인공신경망 모델

딥러닝 기법을 활용한 회귀 모델로, 여러 은닉층을 통해 데이터 간의 복잡한 관계를 학습함

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 139p

4 기계학습 회귀 모델을 이용하여 분석해 볼까?

3 평가

• 세 개 모델의 결정 계수로 각 모델의 성능을 비교함

```

1 def evaluate_model_test(y_test, y_pred, model_name):
2     r2 = r2_score(y_test, y_pred) # 결정 계수
3     print(f'win(model_name) 모델 성능 평가:')
4     print(f'R-squared: (r2)')
5
6 # 선형 회귀 성능 평가
7 evaluate_model_test(y_test, y_pred_lin, '선형 회귀')
8
9 # 랜덤 포레스트 성능 평가
10 evaluate_model_test(y_test, y_pred_rf, '랜덤 포레스트')
11
12 # 인공신경망 성능 평가
13 evaluate_model_test(y_test, y_pred_nn, '인공신경망')

```

선형 회귀 모델 성능 평가:
R-squared: 0.613866475643519

랜덤 포레스트 모델 성능 평가:
R-squared: 0.8101310370904977

인공신경망 모델 성능 평가:
R-squared: 0.6116081686316184

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 139p

4 기계학습 회귀 모델을 이용하여 분석해 볼까?

3 평가

• 세 개 모델의 결정 계수로 각 모델의 성능을 비교함

선형 회귀 모델 성능 평가:
R-squared: 0.613866475643519

랜덤 포레스트 모델 성능 평가:
R-squared: 0.8101310370904977

인공신경망 모델 성능 평가:
R-squared: 0.6116081686316184

랜덤 포레스트 모델의 R-squared 값이 가장 높게 나타나 해당 모델이 가장 우수한 성능을 보인 것으로 평가된다.
이는 랜덤 포레스트가 데이터의 변동성을 효과적으로 설명하며, 예측 오차가 상대적으로 적다는 것을 의미한다.

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 139p

4 기계학습 회귀 모델을 이용하여 분석해 볼까?

3 평가

• 일반적으로 인공신경망은 많은 양의 데이터나 비정형 데이터와 같은 복잡한 데이터를 처리할 때 효과적이지만, 이 경우처럼 데이터의 양이 적고 정형화된 데이터에서

• 이 결과에서는 랜덤 포레스트를 가장 적합한 모델로 평가함

선형 회귀 모델 성능 평가:
R-squared: 0.613866475643519

랜덤 포레스트 모델 성능 평가:
R-squared: 0.8101310370904977

인공신경망 모델 성능 평가:
R-squared: 0.6116081686316184

1. 데이터 모델과 회귀분석 > 1-2. 회귀분석 | 139p

1-2 회귀분석

주요 개념을 점검하기

- 회귀 모델은 여러 변수 간의 관계를 간단한 수식으로 표현하여 주어진 데이터를 바탕으로 예측하는 방법이다. 회귀 모델은 독립 변수의 차수에 따라 선형 회귀와 비선형 회귀로 구분한다.
- 통계적 회귀분석은 해석 가능성과 변수 간의 관계 이해에 초점을 맞추지만, 기계학습 회귀분석은 예측을 위한 성능을 향상시키고 복잡한 패턴을 학습하는 데 중점을 둔다.

「데이터 모델과 회귀분석」 정리

다음 활동을 수행하면서 회귀분석에 대한 내용을 정리해 보자.

지식 이해 1 데이터에서 독립 변수와 종속 변수를 구분해 보고, 이를 바탕으로 회귀 모델을 정의해 보자.

공부 시간	수면 시간	게임 시간	시험 점수
10	6	0	95
9	6	1	90
3	7	3	60
0	8	6	25

- 독립 변수 공부 시간(x_1), 수면 시간(x_2), 게임 시간(x_3)
- 종속 변수 시험 점수(y)
- 회귀 모델 $y = x_1 + x_2 + x_3$

「데이터 모델과 회귀분석」 정리

다음 활동을 수행하면서 회귀분석에 대한 내용을 정리해 보자.

과정 기능 2 1의 시험 점수에 대한 회귀식이 다음과 같을 때 두 개 회귀 모델의 결과를 해석해 보자.

$$y = 4.2x_1 - 2x_2 - 5x_3 + 2.1$$

구분	통계적 회귀 모델	기계학습 회귀 모델
예시	시험 점수에 영향을 미치는 독립 변수는 무엇일까?	기말고사 시험 점수를 얼마나 잘 예측할 수 있을까?
목표	변수 간의 해석과 통계적 유의성 검증	예측의 정확도를 최대화

역량 키워드 「데이터 모델과 회귀분석」 정리

다음 활동을 수행하면서 회귀분석에 대한 내용을 정리해 보자.

과정 기능 2 1의 시험 점수에 대한 회귀식이 다음과 같을 때 두 개 회귀 모델의 결과를 해석해 보자.

구분	통계적 회귀 모델	기계학습 회귀 모델
결과 해석	각 계수의 영향에 중점을 두어 평가한다. 또한 이 계수들이 통계적으로 유의미한지(예: p-value를 통해) 판단하는 것이 중요하다. - 공부 시간 + 1h → 점수 +42점 ↑ - 수면 시간 + 1h → 점수 -2점 ↓ - 게임 시간 + 1h → 점수 -5점 ↓	모델이 시험 점수를 얼마나 정확하게 예측하는지에 초점을 맞춰 모델 성능 지표를 통해 정확성을 평가하고 개별 계수의 해석보다는 전체적인 예측 성능을 극대화하는 데 중점을 둔다.

역량 키워드 「데이터 모델과 회귀분석」 정리

다음 활동을 수행하면서 회귀분석에 대한 내용을 정리해 보자.

가치 태도 3 다른 친구들의 분석 결과를 비교해 보고, 친구들의 해석을 바탕으로 추가적인 분석이나 개선 방안을 제안해 보자.

- 시험 점수에 영향을 줄 수 있는 다른 변수들(예이전 학기 성적, 수업 참여도, 스트레스 지수 등)을 추가로 수집하여 분석에 포함할 것을 제안한다.
- 선형 회귀 모델 외에 다른 종류의 회귀 모델(예: 의사결정트리 회귀, 랜덤 포레스트 회귀 등)을 사용하여 성능을 비교하고 가장 적합한 모델을 선택할 것을 제안한다.

선택 활동 다음 선택 활동 중 나에게 맞는 활동을 선택해 보자.

캐글에서 제공하는 학생 성적 데이터셋(Student Marks Dataset)을 내려받아 선택 활동에 활용해 보자.

#	number_courses	time_study	Marks
3	4.588	19.202	
4	0.896	7.734	
4	3.133	13.811	

변수	의미	자료형
number_courses	과목 수	정수(int)
time_study	공부 시간	실수(float)
Marks	시험 점수	실수(float)

선택 활동 다음 선택 활동 중 나에게 맞는 활동을 선택해 보자.

보충 시험 점수(Marks)를 종속 변수로 하여 회귀분석을 해 보자.

독립 변수	number_courses, time_study	선형 회귀 모델링 생성 및 학습 코드 예시
모델링 결과 분석 평가 및 활용	$y = 1.86x_1 + 5.4x_2 - 7.46$ 의 회귀식을 얻을 수 있다. 이를 통해 높은 점수를 받기 위해서는 5.4의 가중치가 있는 time_study가 매우 중요한 요소임을 알 수 있다.	<pre>from sklearn.linear_model import LinearRegression ln = LinearRegression() model = ln.fit(X,y) model.score(X,y)</pre>

선택 활동 다음 선택 활동 중 나에게 맞는 활동을 선택해 보자.

심화 '학생 성적 데이터셋'으로 통계적 회귀와 기계학습을 통한 회귀(선형 회귀, 앙상블)를 비교해 보자.

통계적 회귀 방법 및 결과	R-squared(결정 계수)는 0.934로, 모델이 종속 변수 'Marks' 변동의 약 93.4%를 설명함을 나타낸다. 이는 매우 높은 설명력을 의미한다. F-statistic의 Prob(F-statistic) 값이 2.90e-46으로 매우 작아, 모델이 통계적으로 유의미함을 알 수 있다.
기계학습을 통한 회귀 방법 및 결과	세 가지 기계 학습 회귀 모델의 R-squared(결정 계수) 성능은 다음과 같다. 선형 회귀: 0.94 • 랜덤 포레스트: 0.99